

AI赋能民族音乐 (2025 暑期)

二、音乐基础模型



大纲

- 什么是音乐基础模型
- 音乐的表示
- 音乐应用任务
- 音乐生成的基础模型



什么是音乐基础模型

“基础模型”这一术语被提出用以描述一种**多用途的机器学习模型**。这类模型**并不是为某一个特定任务**进行训练，而是**作为多个衍生模型的基础**，这些衍生模型可以执行各种不同的任务。

这一术语的出现，标志着**研究重心**从传统上对架构或任务细节的关注，**转向了更普适的模型**，其**涌现能力**和**泛化能力**得以**通过显著增加模型参数数量而被激发**。



什么是音乐基础模型

■ 定义：

- 一种多用途的机器学习模型，支持多种下游任务。
- 与传统为单一任务训练的模型不同，它作为通用基础被广泛适配。

■ 关键特性：

- 参数规模大、能力涌现强。
- 泛化能力强，适用于不同任务与模态。



基础模型的发展背景

■ 推动因素：

- 计算硬件提升。
- 神经网络架构创新（如Transformer）。
- 最小监督训练（如自监督学习，SSL）方法的流行。

■ 训练流程：

- 使用大规模无标签数据进行预训练。
- 通过少量标注数据进行微调或上下文学习（in-context learning）。



代表性语言基础模型

■ 早期代表：

- BERT（双向Transformer编码器）
- GPT系列（生成式预训练Transformer）

■ 优势：

- 利用网页数据训练，摆脱人工标注依赖。
- 推动了自然语言处理的快速发展。





基础模型的多模态扩展

■ 除语言外的应用领域：

- 图像：CLIP、DALIE、Flamingo
- 音频：Audiobox
- 音乐生成：Jukebox、MusicLM、MusicGen
- 机器人控制：RT-2

■ 标志性进展：

- 2022年ChatGPT与Stable Diffusion的发布，引爆AIGC浪潮。





两类音乐相关基础模型

■ 单模态预训练模型


- 在**波形或符号域**中训练，需对**具体下游任务**进行微调。
- 这类模型可以是**用于音乐理解**的PLM变体，如 MERT，也可以是**用于音乐生成**的模型，如 Jukebox。

■ 多模态预训练模型

- 可以同时处理**自然语言和音乐输入**，有望通过“上下文学习”解决多种下游任务。
- 这类模型包括带多文本输入的潜在**扩散模型 (LDMs)**；也包括在**LLM前加入音乐编码器的模型**；以及采用**多模态tokenizer**的LLM。



音乐的基础模型





人工智能在音乐中的应用（近十年）

■ 音乐的基础模型

音乐表示

- 音乐感知与记谱
- 音乐计算机表示
- 多模态音乐表示

应用任务

- 音乐理解
- 音乐生成

基础模型

- LM-based
- Diffusion-based
- LM & Diffusion
- LM + Diffusion





大纲

- 什么是音乐基础模型
- 音乐的表示
- 音乐应用任务
- 音乐生成的基础模型





音乐表示的定义与人类感知

■ 什么是音乐表示 (Music Representations) :

- 用于描述、编码、交流音乐信息的方式
- 可服务于人类思维或计算模型 (如神经网络)
- 音乐的多种表示维度

音高 (Pitch)
节奏 (Rhythm)
和声 (Harmony)
力度 (Dynamics)
表现力 (Expression)
音色 (Timbre)
结构 (Structure)

■ 人类如何感知音乐?

- 在时间域与频率域多尺度感知声音
- 抽象为对音乐概念的感知体验
- 激发多样化的音乐表示设计 (人工或数据驱动)



音乐表示在基础音乐模型中的应用

■ 为什么选择合适的音乐表示很重要？

- 提高准确性：提供有用、相关的信息
- 提升效率：减少计算资源
- 提取特征：利于神经网络识别有意义模式
- 促进泛化：更好适应新任务
- 增强可解释性：更透明和可控的模型设计

■ 表示类型一览

- 人工设计表示：如MIDI、ABC记谱、音符时间序列等
- 可学习表示：如基础模型中使用的音频Token



音乐表示

■ 音乐基础模型中的音乐表示

音乐表示

音乐感知与记谱

音乐计算机表示

多模态音乐表示

□ 人类音乐感知机制

- 声波 → 耳朵 → 神经脉冲 → 大脑解读旋律、节奏、和声、音色
- 耳朵像一组带通滤波器：将声音按频率整合处理
- 临界带（**Critical Band**）：决定频率分辨能力、掩蔽效应与响度感知

□ 音高 (Pitch) 感知

- 音高 = 感知到的频率
- 包含两个维度：
 - 音高色度（**Chroma**）：如所有C音
 - 音高高度（**Height**）：音的高低
- 音高与频率关系非线性，低频更易区分





音乐表示

■ 音乐基础模型中的音乐表示

音乐表示

音乐感知与记谱

音乐计算机表示

多模态音乐表示

□ 节奏与记谱

- 节奏 = 节拍 + 速度 (Tempo) + 节拍组 (Meter)
- 五线谱：通过垂直位置表示音高，通过音符符号表示时值

□ 音色 (Timbre)

- 除了音高、响度、节奏之外的声音特征
- 由频率成分的相对强度决定
- 关键因素：
 - 谐波结构
 - 起音/衰减 (Attack/Decay)
 - 振动/颤音 (Vibrato)
- 音色差异 $\approx$ 频谱差异 (可用滤波器组建模)





音乐表示

■ 音乐基础模型中的音乐表示

音乐表示

音乐感知与记谱

音乐计算机表示

多模态音乐表示

□ 人类感知启发：

- 模拟人耳从声波到神经信号的转换过程，启发不同层级的音乐表示方式。

□ 两大表示层级：

- 声学层级（**Acoustic-level**）：强调声音信号的频谱特征。
- 符号层级（**Symbolic-level**）：强调音乐在音符、节奏、旋律层面的抽象表示。



音乐表示

■ 音乐基础模型中的音乐表示

音乐表示

音乐感知与记谱

音乐计算机表示

多模态音乐表示



(a) Snippet from a musical score in staff notation.

```
\relative c'' {
  \key es \major
  \time 3/4
  \clef treble
  b4 ...}
```

(b) LilyPond

```
*M3/4
*kf
*clefG2
4b
*_
```

(c) **kern

```
X: 1
T: snippet
M: 3/4
K: Eb
L: 1/4
B
```

(d) ABC

```
[\\key<es \\major>
  \\meter<3/4>
  \\clef<"G">
  (b5 a) ...]
```

(e) GUIDO

```
<measure number="1">
  <attributes>
    <divisions>1</divisions>
    <key> <fifths>-3</fifths> </key>
    <time><beats>3</beats><beat-type>4</beat-type></time>
    <clef><sign>G</sign><line>2</line></clef>
  </attributes>
  <note>
    <pitch><step>B</step><octave>5</octave></pitch>
    <duration>4</duration><type>quarter</type>
  </note> ...
</measure>
```

(f) MusicXML

```
<scoreDef xml:id="scoredef-35" key.sig="3f" meter.count="3" meter.unit="4">
  <staffGrp xml:id="staffgrp-11">
    <staffDef xml:id="staffdef-59" clef.shape="G" clef.line="2" n="1" lines="5" />
  </staffGrp>
</scoreDef>
<section xml:id="section-33">
  <measure xml:id="measure-32" right="single">
    <staff xml:id="staff-25" n="1">
      <layer xml:id="layer-55" n="1">
        <note xml:id="note-02" dur="4" oct="5" pname="b" />
      </layer>
    </staff>
  </measure>
```

(g) MEI



音乐表示

■ 音乐基础模型中的音乐表示

音乐表示

音乐感知与记谱

音乐计算机表示

多模态音乐表示




(a) Score Notation

Bar_None Pos. 0.0 Note_Cb6 Dur_16th Pos. 0.0 Note_Ab2 Dur_quarter
Pos. 0.09375 Note_Eb6 Dur_16th Pos. 0.15625 Note_Cb6 Dur_16th
Pos. 0.25 Note_Ab5 Dur_16th Pos. 0.34375 Note_Ab5 Dur_16th
Pos. 0.34375 Note_Ab3 Dur_half Pos. 0.34375 Note_Cb4 Dur_half
Pos. 0.34375 Note_Eb4 Dur_half Pos. 0.40625 Note_Cb6 Dur_16th
Pos. 0.5 Note_Ab5 Dur_16th Pos. 0.59375 Note_Eb5 Dur_16th
Pos. 0.65625 Note_Eb5 Dur_16th Pos. 0.75 Note_Ab5 Dur_16th
Pos. 0.84375 Note_Eb5 Dur_16th Pos. 0.90625 Note_Cb5 Dur_16th Bar_None

(b) REMI tokenization

```
%%score { 1 | 2 }  
L:1/16  
M:3/4  
I:linebreak $  
K:Ab  
V:1 treble nm="Piano" snm="Pno."  
V:2 bass  
L:1/4  
V:1  
_c'e'c'a ac'ae eae_c |] %1  
V:2  
A,, , [A,,_CE]2 |] %1
```

(c) ABC notation



(d) self-defined graph



(e) Generic piano-roll matrix





大纲

- 什么是音乐基础模型
- 音乐的表示
- 音乐应用任务
- 音乐生成的基础模型



音乐应用任务

■ 音乐理解任务

音乐理解

传统音乐信息检索

多模态音乐理解

人声音乐理解

- 与调性与和声相关的任务：调式识别、和弦识别、调性识别
- 与旋律与音高相关的任务：旋律估计、音高与多音高检测、音符追踪、自动音乐转录
- 与节奏相关的任务：起音点检测、节拍与强拍追踪、节拍单位估计、速度估计
- 时间对齐相关任务：乐谱跟踪、音频-乐谱对齐、乐谱对齐
- 声源分离任务：乐器声源分离、谐波-打击乐声源分离
- 音色相关任务：乐器识别、演奏技巧检测
- 片段级分类任务：音乐标签、风格识别、情感/情绪识别
- 基于内容的音频检索：音频指纹识别、音频匹配、翻唱检测
- 时间分段任务：音乐检测、音乐结构分段、时间边界识别
- 带视觉乐谱输入的任务：光学音乐识别及其子任务，如五线谱识别、音乐符号识别
- 与表演理解相关的任务：演奏技巧识别、演奏者识别、演奏评估、演奏难度估计



音乐应用任务


■ 音乐理解任务

音乐理解

传统音乐信息检索

多模态音乐理解

人声音乐理解





音乐应用任务

■ 音乐理解任务

音乐理解

传统音乐信息检索
多模态音乐理解

人声音乐理解

- **歌手识别**: 该任务旨在判断给定音频的演唱者是谁。
- **歌词转录与对齐**: 包括两个子任务: 歌词转录 (识别唱词文本) 和歌词对齐 (获得每个词的时间戳)。
- **歌唱转录**: 该任务的目标是将人声旋律转换为符号音乐 (如 MIDI)。
- **歌声源分离**: 该任务旨在将人声从伴奏中分离出来。
- **歌词解读**: 此任务旨在通过自动摘要技术快速提取歌词核心信息。



音乐应用任务

■ 音乐生成任务

音乐生成

符号音乐生成

声学（乐器）音乐生成

纯人声音乐生成

a) 从零生成（From scratch）：

Multitrack Music Transformer (MMT)

提出多音轨音乐表示 <https://hermandong.com/mmt/>


b) 基于条件生成（Based on condition）：

ChatMusician:

Understanding and Generating Music Intrinsically with LLM

<https://shanghaicannon.github.io/ChatMusician/>

Diff-BGM: A Diffusion Model for Video Background
Music Generation





音乐应用任务

■ 音乐生成任务

音乐生成

符号音乐生成

声学（乐器）音乐生成

纯人声音乐生成

a) 无条件音乐生成

可产生连贯的钢琴音乐延续

AudioLM

A Language Modeling Approach to Audio Generation

<https://google-research.github.io/seanet/audiolm/examples/>

b) 文本到音乐生成

实现可控的音乐生成
(即文本到音乐生成)

AudioGen: Textually-Guided Audio Generation

<https://audiocraft.metademolab.com/audiogen.html>

c) 长时长高质量音乐生成

实现单阶段语言模型
生成高质量音乐样本

MusicGen: Simple and Controllable Music Generation

<https://audiocraft.metademolab.com/musicgen.html>

VidMuse: A Simple Video-to-Music Generation

专注于从视频输入生成音乐

<https://vidmuse.github.io/>

d) 歌词到歌声（器乐加人声）



YuE:

Jukebox: A Generative Model for Music

Open Music Foundation Models for Full-Song Generation



南京大学
NANJING UNIVERSITY



音乐应用任务

■ 音乐生成任务

音乐生成

符号音乐生成

声学（乐器）音乐生成

纯人声音乐生成

a) 歌声合成（**SVS**）：使用歌词结合乐谱来引导语音生成过程

UniSinger: Unified End-to-End Singing Voice Synthesis With Cross-Modality Information Matching

<https://unisinger.github.io/Samples/>

VISinger2: High-Fidelity End-to-end Singing Voice Synthesis Enhanced by Digital Signal Processing Synthesizer

<https://zhangyongmao.github.io/VISinger2/>

b) 歌声转换（**SVC**）：对歌声的多个属性（如音色）进行修改

COMOSVC: Consistency Model-based Singing Voice Conversion

基于一致性模型扩展为多对多转换，兼顾速度和质量

<https://comosvc.github.io/>

SoftVC VITS Singing Voice Conversion

一个影响广泛的开源 SVC 工具

<https://github.com/svc-develop-team/so-vits-svc?tab=readme-ov-file>

LCM-SVC Demo

<https://sounddemos.github.io/lcm-svc/>



南京大学
NANJING UNIVERSITY



大纲

- 什么是音乐基础模型
- 音乐的表示
- 音乐应用任务
- 音乐生成的基础模型



音乐生成的基础模型

■ 音乐生成任务

基础模型

LM

Diffusion

LM & Diffusion

LM + Diffusion

System	Architecture	Size	Max Length	Sample Rate (kHz)	Structure
SongGen [9]	LM	1.1B	30s	16	\usym2715
SongEditor [5]	LM + Diff.	0.7B + 1B	120s	44.1	\usym1F5F8
DiffRhythm-base [3]	Diff.	1.1B	95s	44.1	\usym2715
DiffRhythm-full [3]	Diff.	1.1B	285s	44.1	\usym2715
YuE [4]	LM + LM	7B + 1B	300s	44.1	\usym1F5F8
SongBloom-tiny	LM & Diff.	1.3B	60s	48	\usym1F5F8
SongBloom-full	LM & Diff.	2B	150s	48	\usym1F5F8

Table 1: Comparison of existing song generation models. “+” indicates two cascaded models, while “&” indicates one unified model with jointly optimized objectives.



音乐生成的基础模型

■ 国内外开源模型

MusicGen (Meta)

<https://audiocraft.metademolab.com/musicgen.html>

<https://modelscope.cn/studios/AI-ModelScope/MusicGen>

<https://huggingface.co/spaces/facebook/MusicGen>

DiffRhythm: <https://diffrrhythm.com/>

YuE: <https://github.com/multimodal-art-projection/YuE>

SongGen: <https://liuzh-19.github.io/SongGen/>

SongBloom: https://cypress-yang.github.io/SongBloom_demo/

Songeditor: https://cypress-yang.github.io/SongEditor_demo/

ACE-Step <https://github.com/ace-step/ACE-Step>

SongGeneration <https://github.com/tencent-ailab/SongGeneration>