

软件工程与计算III

迭代三任务说明

软件学院-2025

■ 迭代二补丁

需求分析文档中需说明RAG应用面向的特定领域，并证明在该领域搭建RAG的必要性，最后在设计文档中举例展示RAG应用的实现效果。

TimeLine

- 迭代 1 (4 weeks)

- Week 1: 2.21 授课 发布作业要求; 团队与沟通
- Week 2: 2.28 辅导点名、分组、答疑、检查git
- Week 5: 3.21 晚23:59, 迭代1阶段提交截止

- 迭代 2 (6 weeks)

- Week 5: 3.21 授课 项目团队与沟通
- Week 11: 5.2 晚23:59, 迭代2阶段提交截止

- 迭代3 (6 weeks)

- Week 11: 5.2授课 迭代3项目及检查要求 (劳动节调课安排确定后, 再确定具体时间)
- Week 16: 6.6晚23:59, 迭代3阶段提交

- 期末检查

- Week17-18 项目答辩

■ 迭代三任务介绍

迭代时间： 5 weeks (6月6日晚23:59)

检查方式： 答辩以及助教在线检查

■ 迭代三任务介绍

迭代时间：5 weeks（6月6日晚23:59）

检查方式：答辩以及助教在线检查

迭代三任务内容：

路线一：**RAG产品化** – 围绕迭代二的RAG应用搭建一个特定领域的完整产品

路线二：**RAG优化** – 评估并优化RAG应用的效果

注意：

两条路线**均需**完成1个基本需求点和亮点扩展，**不是**选一个即可

■ 迭代三任务介绍 – RAG产品化

基本需求点：管理员可以在平台上进行可视化的**知识库管理**

该需求点的基本要求为管理员可以在平台上进行已有知识库（原始形式）的查看

加分点在于：1) 支持从系统上添加内容到知识库；

2) 如果用到多个向量数据库，怎样体现知识库与具体向量数据库的对应关系；

3) 如果使用的是混合架构，怎样展现不同数据库中的关系

■ 迭代三任务介绍 – RAG产品化

亮点扩展： 没有具体要求，根据RAG应用所在领域实现除了知识问答以外的**亮点业务功能**

整个的迭代三重点！！！！

亮点功能扩展思路（以一个XX荣耀RAG应用为例）：

该RAG应用的知识库为：英雄技能信息+版本公告+玩家攻略…

方向一：数据分析与可视化 -- 英雄调整趋势折线图、调整报告

方向二：决策支持 -- 组队阵容推荐

方向三：高质量报告生成

…

■ 迭代三任务介绍 – RAG产品化

产物：

1. 一个完整的Web平台：系统可用性高，且并非不相关的功能拼凑；
(如需要使用特殊形式呈现，请提前与助教沟通)
2. 文档：包括不限于需求分析文档、详细设计文档、会议记录

■ 迭代三任务介绍 – RAG优化

基本需求点： 历史对话支持

用户可以与RAG应用进行一次多轮的对话

亮点扩展： 从评估平台的**指标结果**或者一些具体的**Bad Case**出发，对RAG应用的效果进行**优化**

优化的四个基本方向：

向量数据库搭建
优化

检索优化

生成优化

架构优化

推荐阅读：

综述：[Retrieval-Augmented Generation for Large Language Models: A Survey](#)

开源电子书：[动手学大模型应用开发](#) -- 第三、四、五章

■ 迭代三任务介绍 – RAG优化

向量数据库搭建 优化

1. 知识源扩展;
2. 数据格式扩展, 支持pdf, html, md等各种格式的文件读取;
3. 特殊数据内容处理, 例如pdf中的表格;
4. 数据分块优化: 固定token切割、特殊字符切割、标题切割、人工切割、大模型协助切割;
5. 检索前块处理: 去除无关或者重复的块, 添加索引或者必要的元数据

表格序列化: [Large Language Models on Tabular Data: Prediction, Generation, and Understanding -- A Survey](#)

■ 迭代三任务介绍 – RAG优化

检索优化

1. 选用合适的向量数据库：是否支持多种索引、混合搜索等功能；
2. 选用合适的索引策略：相似度检索、最大边际相关性检索、混合索引
3. 特殊案例处理：长文本上下文

■ 迭代三任务介绍 – RAG优化

生成优化

1. 重排序 (rerank) ;
2. 修改优化提示词;
3. 意图识别

架构优化

使用多种类型的数据库，如关系型数据库、图数据库等

■ 迭代三任务介绍 – RAG优化

产物：

1. RAG优化文档：记录了完整的优化过程，包括问题发现、优化具体实现、优化后效果
2. 测试基准集

■ 迭代三任务介绍 – 最后

迭代三的检查重点：

1. 想法设计：RAG应用场景是否合适？功能是否有价值？
2. 工程细节：如何应对AI系统的**随机性**？RAG的数据组织？