

3-24问题汇总

重要问题：RAG搭建方式

经过老师与助教讨论决定，**不推荐**大家使用上传文件就可以生成一个完备知识库的云产品或者框架（直接免去了数据清洗、切分、嵌入、信息召回、rag优化等重要rag实践）。

希望同学们可以自己跑一遍搭建rag的流程，即使最终运行起来的效果可能不尽人意，老师和助教其实是有预期的，大家不用担心。

但是在文档（可以在软件设计文档中，也可以另开一个新的文档）中**一定要**记录好你们实践过程中遇到的问题、思考以及解决方案，比如：

1. 数据搜集阶段：主题需要哪些数据、在哪里获取主题所需的数据、用什么手段获取；

可能的数据搜集手段：

1. 人工：适用于数据量上的情况；
2. 爬虫：爬取网络上的公开数据；
3. 网络接口：一些可以用于获取数据的REST API市场（调用获取各种类型的数据，例如运动、经济、影视等）：

[Nokia acquires Rapid technology and team! 🚀](#)

[APILayer - Best API Marketplace | Reliable, Scalable APIs | APILayer](#)

[数据与API频道页云市场-阿里云](#)

4. 网络上公开的数据集

2. 知识库搭建阶段：数据预处理、如何切分数据，选用哪种数据库持久化数据构建知识库（向量数据库、知识图谱、普通的关系型数据库甚至综合使用多种类型的数据库等等）；
3. 召回与生成阶段：检索方式（通常跟选用的数据库有关）、生成方式等
4. RAG优化阶段（可以延续到迭代三）：知识库丰富、切分方式优化、知识库架构优化、检索方式优化、用户提问优化等。

其他问题

1. RAG应用搭建和评估平台搭建的关系？

这是两个独立的任务，评估平台支持的RAG应用评估面对的不只是你们小组搭建的RAG应用。

可以把两个系统用一个前后端完成，功能齐全即可。

2. RAG评估与Prompt评估的过程？

下面展示两个功能的基本过程（只涉及关键环节）：

RAG评估：用户新建任务 -> 上传评估数据文件 -> 开启一轮评估 -> 后台计算指标并展示 -> 用户改进自己的RAG应用（该环节不在本系统内完成） -> 上传新的评估数据文件 -> 开启下一轮评估 -> 后台计算指标并展示 ...

Prompt评估：用户新建任务 -> 填写prompt -> 获取大模型响应 -> 开启一轮评估 -> 后台计算指标并展示 -> 用户/系统修改prompt（该环节在本系统内完成） -> 获取新的大模型响应 -> 开启下一轮评估 -> 后台计算指标并展示 ...

3. 目录格式？

文档项目必须单开一个，并在其下新建迭代一二三3个子目录，每个迭代将所有文档放入对应目录下；

其余代码项目可以自行创建，在项目根目录下的README简要说明项目功能即可。

4. RAG系统中的大模型需要本地部署吗？

不需要，评估平台使用的大模型也不需要，调用API即可