

第一章 绪论

1. NFL 定理

总误差与学习算法无关。前提是所有“问题”出现的机会相同、或所有问题同等重要。

第二章 模型评估和选择

1. 经验误差、测试误差、泛化误差


经验误差：在训练集上的误差，亦称“训练误差”

测试误差：在测试集上的误差


泛化误差：在训练集外的所有“未来”样本上的误差

2. 留出法、交叉验证法、自助法

留出法：直接将数据集划分为两个互斥集合



交叉验证法：将数据集分层采样划分为 k 个大小相似的互斥子集，每次用 k-1 个子集的并集作为训练集，余下的子集作为测试集，最终返回 k 个测试结果的均值，k 最常用的取值是 10。



自助法：以自助采样法为基础，对数据集 D 有放回采样 m 次得到训练集 D'，D/D' 用做测试集。实际模型与预期模型都使用 m 个训练样本。约 36.8% 的样本不出现。

3. 查准率和查全率

查准率（准确率） $P = \frac{TP}{TP + FP}$

查全率（召回率） $R = \frac{TP}{TP + FN}$

表 2.1 分类结果混淆矩阵

真实情况	预测结果	
	正例	反例
正例	TP (真正例)	FN (假反例)
反例	FP (假正例)	TN (真反例)

4. PR 图

根据学习器的预测结果按正例可能性大小对样例进行排序，并逐个把样本作为正例进行预测，则可以得到查准率-查全率曲线，简称“P-R 曲线”。

5. F1 度量

$$\underline{F1} = \frac{2 * P * R}{P + R} \quad \underline{F\beta} = \frac{(1 + \beta^2) * P * R}{\beta^2 * P + R}$$

6. 宏 xx、微 xx

宏(macro-)查准率、查全率、F1	微(micro-)查准率、查全率、F1
$\text{macro-}P = \frac{1}{n} \sum_{i=1}^n P_i,$ $\text{macro-}R = \frac{1}{n} \sum_{i=1}^n R_i,$ $\text{macro-}F1 = \frac{2 \times \text{macro-}P \times \text{macro-}R}{\text{macro-}P + \text{macro-}R}.$	$\text{micro-}P = \frac{\overline{TP}}{\overline{TP} + \overline{FP}},$ $\text{micro-}R = \frac{\overline{TP}}{\overline{TP} + \overline{FN}},$ $\text{micro-}F1 = \frac{2 \times \text{micro-}P \times \text{micro-}R}{\text{micro-}P + \text{micro-}R}.$

7. ROC、AUC 曲线

ROC 曲线：类似 P-R 曲线，根据学习器的预测结果对样例排序，并逐个作为正例进行预测，以“假正例率”为横轴，“真正例率”为纵轴可得到 ROC 曲线。

$$\text{真正例率 TPR} = \frac{TP}{TP + FN} \quad \text{假正例率 FPR} = \frac{FP}{TN + FP}$$

AUC 是 ROC 曲线下面积大小。

8. 代价曲线


代价曲线的横轴是取值为[0, 1]的正例概率代价（先验概率）

$$P(+)\text{cost} = \frac{p \times \text{cost}_{01}}{p \times \text{cost}_{01} + (1-p) \times \text{cost}_{10}} \quad \begin{array}{l} \text{实际代价} \\ \text{最大代价} \end{array}$$

纵轴是取值为[0, 1]的归一化代价

$$\text{cost}_{\text{norm}} = \frac{\text{FNR} \times p \times \text{cost}_{01} + \text{FPR} \times (1-p) \times \text{cost}_{10}}{p \times \text{cost}_{01} + (1-p) \times \text{cost}_{10}} \quad \begin{array}{l} E_{\text{cost}} \\ \max(E_{\text{cost}}) \end{array}$$

ROC 曲线上每个点对应了代价曲线上的一条线段，设 ROC 曲线上点的坐标为 (FPR, TPR)，则可相应计算出 FNR=1-TPR，然后在代价平面上绘制一条从 (0,FPR)到(1,FNR)的线段，线段下的面积即表示了该条件下的期望总体代价，如此将 ROC 曲线上的每个点转化为代价平面上的一条线段，然后取所有线段的下界，围成的面积即为所有条件下学习器的期望总体代价。



9. 比较检验

两学习器比较：交叉验证 t 检验(基于成对 t 检验)

K 折交叉验证： $\tau_t = \left| \frac{\sqrt{k}\mu}{\sigma} \right|$, 其中 μ 和 σ^2 是测试错误率差值的均值和方差

5*2 交叉验证： $\tau_t = \frac{\mu}{\sqrt{0.2 \sum_{i=1}^5 \sigma_i^2}}$, $\mu = 0.5(\Delta_1^1 + \Delta_1^2)$ $\sigma_i^2 = \left(\Delta_i^1 - \frac{\Delta_1^1 + \Delta_1^2}{2} \right)^2 + \left(\Delta_i^2 - \frac{\Delta_1^1 + \Delta_1^2}{2} \right)^2$

McNemar 检验(基于列联表，卡方检验)： $\tau_{\chi^2} = \frac{(|e_{01} - e_{10}| - 1)^2}{e_{01} + e_{10}}$

多学习器比较：

Friedman 检验 (基于序值，F 检验; 判断“是否都相同”)： $\tau_F = \frac{(N-1)\tau_{\chi^2}}{N(k-1) - \tau_{\chi^2}}$

Nemenyi 后续检验 (基于序值，进一步判断两两差别)： $CD = q_{\alpha} \sqrt{\frac{k(k+1)}{6N}}$

10. 泛化误差


泛化误差： $E(f; D) = bias^2(x) + var(x) + \varepsilon^2$

偏差： $bias^2(x) = (\bar{f}(x) - y)^2$

方差： $var(x) = \mathbb{E}_D [(f(x; D) - \bar{f}(x))^2]$

噪声： $\varepsilon^2 = \mathbb{E}_D [(y_D - y)^2]$

11. 偏差-方差窘境



三、线性模型

1. 线性回归

$$w = \frac{\sum_{i=1}^m y_i (x_i - \bar{x})}{\sum_{i=1}^m x_i^2 - \frac{1}{m} \left(\sum_{i=1}^m x_i \right)^2} \quad b = \frac{1}{m} \sum_{i=1}^m (y_i - wx_i) \quad \bar{x} = \frac{1}{m} \sum_{i=1}^m x_i$$



2. 对数几率回归

$$\ln \frac{y}{1-y} = \mathbf{w}^T \mathbf{x} + b$$

，可以算出

$$p(y=1|\mathbf{x}) = \frac{e^{\mathbf{w}^T \mathbf{x} + b}}{1 + e^{\mathbf{w}^T \mathbf{x} + b}}$$
$$p(y=0|\mathbf{x}) = \frac{1}{1 + e^{\mathbf{w}^T \mathbf{x} + b}}$$

四、决策树

1. 信息熵

$$\text{Ent}(D) = - \sum_{k=1}^{|Y|} p_k \log_2 p_k$$

， $\text{Ent}(D)$ 的值越小，则 D 的纯度越高。其中， p_k 是当前样本集合 D 中第 k 类样本所占的比例， y 是样本的类别数量。

2. 信息增益

$$\text{Gain}(D, a) = \text{Ent}(D) - \sum_{v=1}^V \frac{|D^v|}{|D|} \text{Ent}(D^v)$$

，其中 D^v : D 中在 a 上取值= a^v 的样本集合。

3. 增益率

$$\text{Gain_ratio}(D, a) = \frac{\text{Gain}(D, a)}{\text{IV}(a)}$$

，其中，属性固有值 $\text{IV}(a)=$

$$- \sum_{v=1}^V \frac{|D^v|}{|D|} \log_2 \frac{|D^v|}{|D|}$$

4. 基尼指数

$$\text{Gini}(D) = \sum_{k=1}^{|Y|} \sum_{k' \neq k} p_k p_{k'} = 1 - \sum_{k=1}^{|Y|} p_k^2$$

，基尼指数越小，数据集 D 的纯度越高。

$$\text{Gini_index}(D, a) = \sum_{v=1}^V \frac{|D^v|}{|D|} \text{Gini}(D^v)$$

属性 a 的基尼指数：

，选取那个使划分后基尼指数最小的属性。

5. 预剪枝和后剪枝

预剪枝：

决策树生成过程中，对每个结点在划分前先进行估计，若当前结点的划分不能带来决策树泛化性能提升，则停止划分并将当前结点记为叶结点，其类别标记为训练样例数最多的类别。

优点：降低过拟合风险，显著减少训练时间和测试时间开销。

缺点：欠拟合风险：有些分支的当前划分虽然不能提升泛化性能，但在其基础上进行的后续划分却有可能导致性能显著提高。预剪枝基于“贪心”本质禁止这些分支展开，带来了欠拟合风险。

后剪枝：

先从训练集生成一棵完整的决策树，然后自底向上地对非叶结点进行考察，若将该结点对应的子树替换为叶结点能带来决策树泛化性能提升，则将该子树替换为叶结点。

优点：后剪枝比预剪枝保留了更多的分支，欠拟合风险小，泛化性能往往优于预剪枝决策树。

缺点：训练时间开销大：后剪枝过程是在生成完全决策树之后进行的，需要自底向上对所有非叶结点逐一考察。

6. 连续值处理

第一步：选取候选划分点集合。

$$T_a = \left\{ \frac{a^i + a^{i+1}}{2} \mid 1 \leq i \leq n-1 \right\}$$

第二步：选取最优的划分点。

$$\text{Gain}(D, a) = \max_{t \in T_a} \text{Gain}(D, a, t) = \max_{t \in T_a} \text{Ent}(D) - \sum_{\lambda \in \{-, +\}} \frac{|D_t^\lambda|}{|D|} \text{Ent}(D_t^\lambda)$$

7. 缺失值处理

基本思路：样本赋权，权重划分。

$\tilde{D}$ 表示 D 中在属性 a 上没有缺失值的样本子集， $\tilde{D}^v$ 表示 $\tilde{D}$ 中在属性 a 上取值为 a^v 的样本子集， $\tilde{D}_k$ 表示 $\tilde{D}$ 中属于第 k 类的样本子集。

无缺失值样本所占的比例：
$$\rho = \frac{\sum_{x \in \tilde{D}} w_x}{\sum_{x \in D} w_x}$$

无缺失值样本中第 k 类所占比例：
$$\tilde{p}_k = \frac{\sum_{x \in \tilde{D}_k} w_x}{\sum_{x \in \tilde{D}} w_x} \quad (1 \leq k \leq |\mathcal{Y}|)$$

无缺失值样本中在属性 a 上取值 a^v 的样本所占比：
$$\tilde{r}_v = \frac{\sum_{x \in \tilde{D}^v} w_x}{\sum_{x \in \tilde{D}} w_x} \quad (1 \leq v \leq V)$$

$$\begin{aligned} \text{Gain}(D, a) &= \rho \times \text{Gain}(\tilde{D}, a) \\ &= \rho \times \left(\text{Ent}(\tilde{D}) - \sum_{v=1}^V \tilde{r}_v \text{Ent}(\tilde{D}^v) \right) \\ \text{Ent}(\tilde{D}) &= - \sum_{k=1}^{|\mathcal{Y}|} \tilde{p}_k \log_2 \tilde{p}_k \end{aligned}$$

若样本 x 在划分属性 a 上的取值已知，则将 x 划入与其取值对应的子结点，且样本权值在子结点中保持为 w_x 。

若样本 x 在划分属性 a 上的取值未知，则将 x 同时划入所有子结点，且样本权值在与属性值 a^v 对应的子结点中调整为 $\tilde{r}_v * w_x$ (直观来看，相当于让同一个样本以不同概率划入不同的子结点中去)

五、神经网络

1. sigmoid 函数

$$\text{sigmoid}(x) = \frac{1}{1+e^{-x}}$$

2. 前馈网络

神经元之间不存在同层连接也不存在跨层连接。

3. BP 算法（误差逆传播算法）




图 5.7 BP 网络及算法中的变量符号

输出层第 j 个神经元的阈值用 θ_j 表示，隐层第 h 个神经元的阈值用 γ_h 表示。

$$\hat{y}_j^k = f(\beta_j - \theta_j) \quad \text{均方误差} \quad E_k = \frac{1}{2} \sum_{j=1}^l (\hat{y}_j^k - y_j^k)^2$$

网络中有 $(d+l+1)q + l$ 个参数需确定。

$$\Delta w_{hj} = \eta g_j b_h, \quad \Delta \theta_j = -\eta g_j, \quad \Delta v_{ih} = \eta e_h x_i, \quad \Delta \gamma_h = -\eta e_h$$

其中，

$$g_j = -\frac{\partial E_k}{\partial \hat{y}_j^k} \cdot \frac{\partial \hat{y}_j^k}{\partial \beta_j} = \hat{y}_j^k (1 - \hat{y}_j^k) (y_j^k - \hat{y}_j^k)$$

$$e_h = -\frac{\partial E_k}{\partial b_h} \cdot \frac{\partial b_h}{\partial \alpha_h} = b_h (1 - b_h) \sum_{j=1}^l w_{hj} g_j, \quad \eta \text{ 是学习率, } b_h \text{ 是隐层输出值。}$$

4. 缓解 BP 算法过拟合

(1) 早停：若训练误差连续 a 轮的变化小于 b ，则停止训练；使用验证集：若训练误差降低、验证误差升高，则停止训练。

(2) 正则化：在误差目标函数中增加一项描述网络复杂度。

$$E = \lambda \frac{1}{m} \sum_{k=1}^m E_k + (1 - \lambda) \sum_i w_i^2, \quad \text{其中 } w_i \text{ 是连接权和阈值。}$$

5. RBF 神经网络

单隐层前馈神经网络。使用径向基函数作为隐层神经元激活函数，例如高斯径向基函数：

$$\rho(\mathbf{x}, \mathbf{c}_i) = e^{-\beta_i \|\mathbf{x} - \mathbf{c}_i\|^2}$$

输出层是隐层神经元输出的线性组合： $\varphi(\mathbf{x}) = \sum_{i=1}^q w_i \rho(\mathbf{x}, \mathbf{c}_i)$

6. ART 网络

竞争学习是神经网络中一种常用的无监督学习策略，在使用该策略时，网络的输出神经元相互竞争，每一时刻仅有一个神经元被激活，其他神经元的状态被抑制。

ART 网络是竞争学习的重要代表。ART 网络由比较层、识别层、识别阈值和重置模块构成。比较层负责接收输入样本，并将其传送给识别层神经元。识别层每个神经元对应一个模式类，神经元的数目可在训练过程中动态增长以增加新的模式类。

ART 网络性能依赖于识别阈值。识别阈值高时，输入样本将会分成比较多、得到较精细分类。

优势：ART 较好的解决了竞争学习中的“可塑性-稳定性窘境”，可塑性是指神经网络要有学习新知识的能力；稳定性是指神经网络在学习新知识时要保持对旧知识的记忆。ART 网络可以增量学习或在线学习。

7. SOM 神经网络

竞争型的无监督神经网络。将高维数据映射到低维空间（通常为 2 维），高维空间中相似的样本点映射到网络输出层中邻近神经元。每个神经元拥有一个权向量。目标：为每个输出层神经元找到合适的权向量以保持拓扑结构。

8. 级联相关网络

构造性神经网络：将网络的结构也当做学习的目标之一，希望在训练过程中找到适合数据的网络结构。开始时只有输入层和输出层，级联 - 新的隐层结点逐渐加入，从而创建起层级结构，相关 - 最大化新结点的输出与网络误差之间的相关性。

9. Hopfield 网络

反馈型神经网络。主要用于存储和检索记忆（数据模式）。

10. Elman 网络

递归神经网络。结构与前馈神经网络很相似，但隐层神经元的输出被反馈回来。

11. Boltzmann 机

神经网络中有一类模型为网络定义一个“能量”，能量最小化时网络达到理想状态，而网络的训练就是在最小化这个能量函数。

Boltzmann 机就是一种基于能量的模型。

12. 提升性能的重要诀窍

(1) 预训练+微调：监督逐层训练，每次训练一层隐结点。预训练全部完成后，对全网络进行微调训练。

(2) 权共享：一组神经元使用相同的连接权值。

(3) Dropout：在每轮训练时随机选择一些参数令其不被更新(下一轮可能被更新)。

(4) ReLU：将 Sigmoid 激活函数修改为修正线性函数 $f(x)=\max(0,x)$

(5) 交叉熵：BP 算法中以交叉熵 $-\frac{1}{m} \sum_{i=1}^m y_i \log \hat{y}_i$ 代替均方误差。

六、支持向量机

1. 间隔与支持向量

超平面线性方程: $\mathbf{w}^T \mathbf{x} + b = 0$, $\mathbf{w}$ 为法向量, b 为偏移量。

样本空间中任意点 $\mathbf{x}$ 到超平面 $(\mathbf{w}, b)$ 的距离: $r = \frac{|\mathbf{w}^T \mathbf{x} + b|}{\|\mathbf{w}\|}$

支持向量: $\mathbf{w}^T \mathbf{x} + b = \pm 1$ 。

间隔: $\gamma = \frac{2}{\|\mathbf{w}\|}$

目标是寻找参数 $\mathbf{w}$ 和 b , 使得 γ 最大, 即:

$$\begin{aligned} \arg \max_{\mathbf{w}, b} \quad & \frac{2}{\|\mathbf{w}\|} \\ \text{s.t.} \quad & y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1, \quad i = 1, 2, \dots, m. \end{aligned} \quad \text{即:} \quad \begin{aligned} \arg \min_{\mathbf{w}, b} \quad & \frac{1}{2} \|\mathbf{w}\|^2 \\ \text{s.t.} \quad & y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1, \quad i = 1, 2, \dots, m. \end{aligned}$$

2. 最终模型 (支持向量机 SVM)

最终模型: $f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i^T \mathbf{x} + b$

KKT 条件:

$$\begin{cases} \alpha_i \geq 0; \\ 1 - y_i f(\mathbf{x}_i) \leq 0; \\ \alpha_i (1 - y_i f(\mathbf{x}_i)) = 0. \end{cases}$$

解的稀疏性: 训练完成后, 最终模型仅与支持向量有关。

3. 核函数

核函数: $\kappa(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j)$

Mercer 定理: 若一个对称函数所对应的核矩阵半正定, 则它就能作为核函数来使用。

名称	表达式	参数
线性核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i^T \mathbf{x}_j$	
多项式核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i^T \mathbf{x}_j)^d$	$d \geq 1$ 为多项式的次数
高斯核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\ \mathbf{x}_i - \mathbf{x}_j\ ^2}{2\sigma^2}\right)$	$\sigma > 0$ 为高斯核的带宽(width)
拉普拉斯核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\ \mathbf{x}_i - \mathbf{x}_j\ }{\sigma}\right)$	$\sigma > 0$
Sigmoid 核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \tanh(\beta \mathbf{x}_i^T \mathbf{x}_j + \theta)$	$\tanh$ 为双曲正切函数, $\beta > 0, \theta < 0$

基本经验: 文本数据常用线性核, 情况不明时可先尝试高斯核。

4. 软间隔优化目标

基本思路: 最大化间隔的同时, 让不满足约束 $y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1$ 的样本尽可能少。

优化目标可写为: $\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \ell_{0/1}(y_i(\mathbf{w}^T \mathbf{x}_i + b) - 1)$

引入松弛变量 ξ_i ，优化问题变为：

$$\begin{aligned} \min_{w, b, \xi_i} \quad & \frac{1}{2} \|w\|^2 + C \sum_{i=1}^m \xi_i \\ \text{s.t.} \quad & y_i(w^T x_i + b) \geq 1 - \xi_i, \xi_i \geq 0, i = 1, 2, \dots, m. \end{aligned}$$

5. 支持向量回归 (SVR)

原始问题：

$$\begin{aligned} \min_{w, b, \xi_i, \hat{\xi}_i} \quad & \frac{1}{2} \|w\|^2 + C \sum_{i=1}^m (\xi_i + \hat{\xi}_i) \\ \text{s.t.} \quad & f(x_i) - y_i \leq \epsilon + \xi_i, \\ & y_i - f(x_i) \leq \epsilon + \hat{\xi}_i, \\ & \xi_i \geq 0, \hat{\xi}_i \geq 0, i = 1, 2, \dots, m \end{aligned}$$

预测：

$$f(x) = \sum_{i=1}^m (\hat{\alpha}_i - \alpha_i) x_i^T x + b$$

七、贝叶斯分类器

1. 贝叶斯决策论

给定 N 个类别，令 λ_{ij} 代表将第 j 类样本误分类为第 i 类所产生的损失，则基于后验概率将样本 x 分到第 i 类的条件风险为：

$$R(c_i | x) = \sum_{j=1}^N \lambda_{ij} P(c_j | x)$$

贝叶斯判定准则： $h^*(x) = \arg \min_{c \in \mathcal{Y}} R(c | x)$ ， h^* 称为贝叶斯最优分类器，其总体风险称为贝叶斯风险，反映了学习性能的理论上限。

2. 贝叶斯定理

$P(c | x) = \frac{P(c) P(x | c)}{P(x)}$ ，其中 $P(c)$ 是类“先验”概率； $P(x)$ 是证据因子； $P(x|c)$ 是类条件概率，或称为“似然”。

3. 极大似然估计

θ_c 对于训练集 D 中第 c 类样本组成的集合 D_c 的似然为：

$$P(D_c | \theta_c) = \prod_{x \in D_c} P(x | \theta_c)$$

通常使用对数似然：

$$LL(\theta_c) = \log P(D_c | \theta_c) = \sum_{x \in D_c} \log P(x | \theta_c)$$

θ_c 的极大似然估计：

$$\hat{\theta}_c = \arg \max_{\theta_c} LL(\theta_c)$$

4. 朴素贝叶斯分类器

基本思路：假定属性相互独立。

$$P(c | \mathbf{x}) = \frac{P(c) P(\mathbf{x} | c)}{P(\mathbf{x})} = \frac{P(c)}{P(\mathbf{x})} \prod_{i=1}^d P(x_i | c)$$

$$h_{nb}(\mathbf{x}) = \arg \max_{c \in \mathcal{Y}} P(c) \prod_{i=1}^d P(x_i | c)$$

估计 $P(c)$:

$$P(c) = \frac{|D_c|}{|D|}$$

估计 $P(x_i | c)$: 对离散属性, 令 D_{c, x_i} 表示 D 中在第 i 个属性上取值为 x_i 的样本组成的集合,

则

$$P(x_i | c) = \frac{|D_{c, x_i}|}{|D_c|}.$$

对连续属性, 考虑概率密度函数, 假定 $p(x_i | c) \sim \mathcal{N}(\mu_{c, i}, \sigma_{c, i}^2)$, 则

$$p(x_i | c) = \frac{1}{\sqrt{2\pi}\sigma_{c, i}} \exp\left(-\frac{(x_i - \mu_{c, i})^2}{2\sigma_{c, i}^2}\right)$$

5. 拉普拉斯修正

令 N 表示训练集 D 中可能的类别数, N_i 表示第 i 个属性可能的取值数。

$$\hat{P}(c) = \frac{|D_c| + 1}{|D| + N}, \quad \hat{P}(x_i | c) = \frac{|D_{c, x_i}| + 1}{|D_c| + N_i}$$

6. 朴素贝叶斯分类器的使用

- (1) 若对预测速度要求高, 预计算所有概率估值, 使用时“查表”。
- (2) 若数据更替频繁, 不进行任何训练, 收到预测请求时再估值。(懒惰学习)
- (3) 若数据不断增加, 基于现有估值, 对新样本涉及的概率估值进行修正。(增量学习)

7. 半朴素贝叶斯分类器

基本思路：适当考虑一部分属性间的相互依赖信息。

最常用策略：独依赖估计。假设每个属性在类别之外最多仅依赖一个其他属性。

$$P(c | \mathbf{x}) \propto P(c) \prod_{i=1}^d P(x_i | c, pa_i)$$

其中, pa_i 为属性 x_i 所依赖的属性, 称为 x_i 的父属性。

SPODE: 假设所有属性都依赖于同一属性, 称为“超父”, 然后通过交叉验证等模型选择方法来确定超父属性。

TAN: 以属性间的条件“互信息”为边的权重, 构建完全图, 再利用最大带权生成树算法, 仅保留强相关属性间的依赖性。

8. AODE

尝试将每个属性作为超父构建 SPODE，将拥有足够训练数据支撑的 SPODE 集成起来作为最终结果。

9. 贝叶斯网

有向无环图。给定父结点集，贝叶斯网假设每个属性与其非后裔属性独立。




图 7.3 贝叶斯网中三个变量之间的典型依赖关系

在同父结构中，给定父节点 x_1 的取值，则 x_3 与 x_4 条件独立。

在顺序结构中，给定 x 的取值，则 y 和 z 条件独立。

V 型结构亦称“冲撞”结构，给定子结点 x_4 的取值， x_1 与 x_2 必不独立；若 x_4 的取值完全未知，则 V 型结构下 x_1 和 x_2 是相互独立的。

10. 分析条件独立性

先将有向图转变为无向图：将 V 型结构的父结点相连，有向边变成无向边。

假定道德图中有变量 x, y 和变量集合 $z = \{z_i\}$ 。若 x 和 y 能在图上被 z 分入两个连通分支，则有 $x \perp y | z$ 。

11. 评分函数

用于评估贝叶斯网与训练数据的契合程度。

12. 吉布斯采样

随机产生一个与证据 $E = e$ 一致的样本 q^0 作为初始点。进行 T 次采样，每次采样中逐个考察每个非证据变量：假定所有其他属性取当前值，推断出采样概率，然后根据该概率采样。假定经过 T 次采样的得到与“查询目标” q 一致的样本共有 n_q 个，则可近似估算出后验

概率： $P(Q = q | E = e) \simeq \frac{n_q}{T}$

13. EM 算法

最大化对数“边际似然”： $LL(\Theta | \mathbf{X}) = \ln P(\mathbf{X} | \Theta) = \ln \sum_{\mathbf{Z}} P(\mathbf{X}, \mathbf{Z} | \Theta)$

E 步：以当前参数推断隐变量分布 $P(\mathbf{Z} | \mathbf{X}, \Theta^t)$ 并计算对数似然 $LL(\Theta | \mathbf{X}, \mathbf{Z})$ 关于 $\mathbf{Z}$ 的期望。

$$Q(\Theta | \Theta^t) = \mathbb{E}_{\mathbf{Z} | \mathbf{X}, \Theta^t} LL(\Theta | \mathbf{X}, \mathbf{Z})$$

M 步：寻找参数最大化期望似然，即：

$$\Theta^{t+1} = \arg \max_{\Theta} Q(\Theta | \Theta^t)$$

八、集成学习

1. 集成学习方法分类

(1) 序列化方法: AdaBoost, GradientBoost

(2) 并行化方法: Bagging, Random Forest, Random Subspace

2. Boosting

特点: 个体学习器存在强依赖关系; 串行生成。

方法: 每次调整训练数据的样本分布。

注意事项: 训练的每一轮都检查当前生成的基分类器是否比随机猜测好。

对特定的数据分布进行学习, 可采用重赋权法和重采样法, 可获得“重启动”机会以避免训练过程过早停止。

3. AdaBoost

基学习器的线性组合:
$$H(x) = \sum_{t=1}^T \alpha_t h_t(x)$$

最小化指数损失函数:
$$\ell_{\text{exp}}(H | \mathcal{D}) = \mathbb{E}_{x \sim \mathcal{D}}[e^{-f(x)H(x)}]$$

令损失函数关于 $H(x)$ 的偏导等于 0 得:
$$H(x) = \frac{1}{2} \ln \frac{P(f(x) = 1 | x)}{P(f(x) = -1 | x)}$$

基分类器的权重:
$$\alpha_t = \frac{1}{2} \ln \left(\frac{1 - \epsilon_t}{\epsilon_t} \right)$$

理想的基学习器:
$$h_t(x) = \arg \min_h \mathbb{E}_{x \sim \mathcal{D}_t} [\mathbb{I}(f(x) \neq h(x))]$$

样本分布更新公式:
$$\mathcal{D}_{t+1}(x) = \frac{\mathcal{D}(x) e^{-f(x)H_t(x)}}{\mathbb{E}_{x \sim \mathcal{D}}[e^{-f(x)H_t(x)}]} = \mathcal{D}_t(x) \cdot e^{-f(x)\alpha_t h_t(x)} \frac{\mathbb{E}_{x \sim \mathcal{D}}[e^{-f(x)H_{t-1}(x)}]}{\mathbb{E}_{x \sim \mathcal{D}}[e^{-f(x)H_t(x)}]}$$

4. Bagging

特点: 个体学习器不存在强依赖关系; 并行化生成; 时间复杂度低; 可使用包外估计。

方法: 通过对训练样本采样使基学习器尽可能具有较大的差异。如自助采样法。

5. 包外估计

$H^{\text{oob}}(x)$ 表示对样本 x 的包外预测, 即仅考虑那些未使用样本 x 训练的基学习器在 x 上的预

测:
$$H^{\text{oob}}(x) = \arg \max_{y \in \mathcal{Y}} \sum_{t=1}^T \mathbb{I}(h_t(x) = y) \cdot \mathbb{I}(x \notin D_t)$$

Bagging 泛化误差的包外估计为:
$$\epsilon^{\text{oob}} = \frac{1}{|D|} \sum_{(x,y) \in D} \mathbb{I}(H^{\text{oob}}(x) \neq y)$$

6. 随机森林

随机森林(简称 RF)是 Bagging 的一个扩展变体。

(1) 采样的随机性。

(2) 属性选择的随机性: 对基决策树的每个结点, 先从该结点的属性集合中随机选择一个包含 k 个属性的子集, 然后再从这个子集中选择一个最优属性用于划分。

7. 学习器结合

(1) 平均法：用于数值型输出，包括简单平均法、加权平均法。

(2) 投票法：用于分类任务，包括绝对多数投票法、相对多数投票法、加权投票法。

$$H(x) = \begin{cases} c_j & \text{if } \sum_{i=1}^T h_i^j(x) > \frac{1}{2} \sum_{k=1}^I \sum_{i=1}^T h_i^k(x) \\ \text{rejection} & \text{otherwise} \end{cases}$$

绝对多数投票法：

$$H(x) = c_{\arg \max_j \sum_{i=1}^T h_i^j(x)}$$

相对多数投票法：

$$H(x) = c_{\arg \max_j \sum_{i=1}^T w_i h_i^j(x)}$$

加权投票法：

(3) 学习法：Stacking、贝叶斯模型平均。

8. 误差-分歧分解

$$A(h_i | x) = (h_i(x) - H(x))^2$$

定义学习器 h_i 的分歧：

E 为集成的泛化误差； $\bar{E} = \sum_{i=1}^T w_i E_i$ 表示个体学习器泛化误差的加权均值； $\bar{A} = \sum_{i=1}^T w_i A_i$ 表示个体学习器的加权分歧值，有：

$$E = \bar{E} - \bar{A}$$

个体学习器准确性越高、多样性越大，则集成效果越好。称为误差-分歧分解。

9. 多样性度量

一般通过两分类器的预测结果列联表定义，如下图所示：

	$h_i = +1$	$h_i = -1$
$h_j = +1$	a	c
$h_j = -1$	b	d

(m 为数据集数据个数)

$$(1) \text{ 不合度量: } dis_{ij} = \frac{b+c}{m}$$

$$(2) \text{ 相关系数: } \rho_{ij} = \frac{ad-bc}{\sqrt{(a+b)(a+c)(c+d)(b+d)}}$$

$$(3) \text{ Q-统计量: } Q_{ij} = \frac{ad-bc}{ad+bc}, \quad |Q_{ij}| \geq |\rho_{ij}|$$

$$(4) \text{ \kappa-统计量: } \kappa = \frac{p_1 - p_2}{1 - p_2}, \quad p_1 = \frac{a+d}{m}, \quad p_2 = \frac{(a+b)(a+c) + (c+d)(b+d)}{m^2}$$

10. 多样性增强常用策略

(1) 数据样本扰动：通常是基于采样法，如 Bagging 中的自助采样、AdaBoost 中的序列采样。数据样本扰动对“不稳定基学习器”很有效，如决策树，神经网络等，稳定基学习器包括线性学习器，支持向量机，朴素贝叶斯，k 近邻等。

(2) 输入属性扰动：如随机子空间算法

(3) 输出表示扰动：如翻转法：随机改变一些训练样本的标记；输出调制法：将分类输出转化为回归输出后构建个体学习器；将原任务拆解为多个可同时求解的子任务 (ECOC)。

(4) 算法参数扰动：随机设置不同的参数。

九、聚类

1. 聚类目标

将数据样本划分为若干个通常不相交的“簇”。

2. 性能度量

聚类性能度量，亦称聚类“有效性指标”。

(1) 外部指标：将聚类结果与某个“参考模型”进行比较。如 Jaccard 系数，FM 指数，Rand 指数。

(2) 内部指标：直接考察聚类结果而不用任何参考模型。如 DB 指数，Dunn 指数等。
基本想法：“簇内相似度”高，且“簇间相似度”低。

3. 外部指标

对数据集 $D=\{x_1, x_2, \dots, x_m\}$ ，通过聚类得到的簇划分为 $C=\{C_1, C_2, \dots, C_k\}$ ，参考模型给出的簇划分为 $C^*=\{C_1^*, C_2^*, \dots, C_s^*\}$ 。相应地，令 λ 与 λ^* 分别表示与 C 和 C^* 对应的簇标记向量。我们将样本两两配对考虑，定义：

$$\begin{aligned} a &= |SS|, SS = \{(x_i, x_j) | \lambda_i = \lambda_j, \lambda_i^* = \lambda_j^*, i < j\} \\ b &= |SD|, SD = \{(x_i, x_j) | \lambda_i = \lambda_j, \lambda_i^* \neq \lambda_j^*, i < j\} \\ c &= |DS|, DS = \{(x_i, x_j) | \lambda_i \neq \lambda_j, \lambda_i^* = \lambda_j^*, i < j\} \\ d &= |DD|, DD = \{(x_i, x_j) | \lambda_i \neq \lambda_j, \lambda_i^* \neq \lambda_j^*, i < j\} \end{aligned}$$

(1) Jaccard 系数： $JC = \frac{a}{a+b+c}$

(2) FM 指数： $FMI = \sqrt{\frac{a}{a+b} \cdot \frac{a}{a+c}}$

(3) Rand 指数： $RI = \frac{2(a+b)}{m(m-1)}$

三个指数都在[0,1]区间内。越大越好。

4. 内部指标

考虑聚类结果的簇划分 $C=\{C_1, C_2, \dots, C_k\}$ ，定义：

簇 C 内样本间的平均距离： $avg(C) = \frac{2}{|C|(|C|-1)} \sum_{1 \leq i < j \leq |C|} dist(x_i, x_j)$

簇 C 内样本间的最远距离： $diam(C) = \max_{1 \leq i < j \leq |C|} dist(x_i, x_j)$

簇 C_i 与簇 C_j 最近样本间的距离： $d_{min}(C) = \min_{x_i \in C_i, x_j \in C_j} dist(x_i, x_j)$

簇 C_i 与簇 C_j 中心点间的距离： $d_{cen}(C) = dist(\mu_i, \mu_j)$

DB 指数 (DBI)： $DBI = \frac{1}{k} \sum_{i=1}^k \max_{j \neq i} \left(\frac{avg(C_i) + avg(C_j)}{d_{cen}(C_i, C_j)} \right)$ 。越小越好。

Dunn 指数 (DI)： $DI = \min_{1 \leq i \leq k} \left\{ \min_{j \neq i} \left(\frac{d_{min}(C_i, C_j)}{\max_{1 \leq l \leq k} diam(C_l)} \right) \right\}$ 。越大越好。

5. 距离度量需满足的基本性质

非负性: $\text{dist}(x_i, x_j) \geq 0$;
同一性: $\text{dist}(x_i, x_j) = 0$ 当且仅当 $x_i = x_j$;
对称性: $\text{dist}(x_i, x_j) = \text{dist}(x_j, x_i)$;
直递性: $\text{dist}(x_i, x_j) \leq \text{dist}(x_i, x_k) + \text{dist}(x_k, x_j)$.

6. 常用距离形式

闵可夫斯基距离:

$$\text{dist}_{\text{mk}}(x_i, x_j) = \left(\sum_{u=1}^n |x_{iu} - x_{ju}|^p \right)^{\frac{1}{p}}$$

p = 2: 欧氏距离; p = 1: 曼哈顿距离

7. VDM 和 MinkovDM

对无序属性, 可使用 VDM 计算距离:

令 $m_{u,a}$ 表示属性 u 上取值为 a 的样本数, $m_{u,a,i}$ 表示在第 i 个样本簇中在属性 u 上取值为 a 的样本数, k 为样本簇数, 则属性 u 上两个离散值 a 与 b 之间的 VDM 距离为:

$$\text{VDM}_p(a, b) = \sum_{i=1}^k \left| \frac{m_{u,a,i}}{m_{u,a}} - \frac{m_{u,b,i}}{m_{u,b}} \right|^p$$

对混合属性, 可使用 MinkovDM 计算距离:

$$\text{MinkovDM}_p(x_i, x_j) = \left(\sum_{u=1}^{n_c} |x_{iu} - x_{ju}|^p + \sum_{u=n_c+1}^n \text{VDM}_p(x_{iu}, x_{ju}) \right)^{\frac{1}{p}}$$

8. 常见聚类方法

(1) 原型聚类, 亦称“基于原型的聚类”

假设: 聚类结构能通过一组原型刻画

过程: 先对原型初始化, 然后对原型进行迭代更新求解

代表: k 均值聚类, 学习向量量化(LVQ), 高斯混合聚类

(2) 密度聚类, 亦称“基于密度的聚类”

假设: 聚类结构能通过样本分布的紧密程度确定

过程: 从样本密度的角度来考察样本之间的可连接性, 并基于可连接样本不断扩展

聚类簇

代表: DBSCAN, OPTICS, DENCLUE

(3) 层次聚类

假设: 能够产生不同粒度的聚类结果

过程: 在不同层次对数据集进行划分, 从而形成树形的聚类结构

代表: AGNES(自底向上), DIANA(自顶向下)

9. k 均值算法

即最小化平方误差 $E = \sum_{i=1}^k \sum_{x \in C_i} \|x - \mu_i\|_2^2$, 其中, μ_i 是簇 C_i 的均值向量。

E 值在一定程度上刻画了簇内样本围绕簇均值向量的紧密程度，E 值越小，则簇内样本相似度越高。

算法流程：

Step1: 随机选取 k 个样本点作为簇中心

Step2: 将其他样本点根据其与簇中心的距离，划分给最近的簇

Step3: 更新各簇的均值向量，将其作为新的簇中心

Step4: 若所有簇中心未发生改变，则停止；否则执行 Step 2

10. 学习向量量化 (LVQ)

与一般聚类算法不同的是，LVQ 假设数据样本带有类别标记，学习过程中利用样本的这些监督信息来辅助聚类。也是试图找到一组原型向量来刻画聚类结构，但假设数据样本带有类别标记，实际上是通过聚类来形成类别的“子类”结构，每个子类对应一个聚类簇。

11. 高斯混合聚类 (GMM)

与 k 均值、LVQ 用原型向量来刻画聚类结构不同，高斯混合聚类采用概率模型来表达聚类原型。

高斯混合分布的定义：

$$p_{\mathcal{M}}(x) = \sum_{i=1}^k \alpha_i \cdot p(x | \mu_i, \Sigma_i)$$

考虑最大化对数似然：

$$LL(D) = \ln \left(\prod_{j=1}^m p_{\mathcal{M}}(x_j) \right) = \sum_{j=1}^m \ln \left(\sum_{i=1}^k \alpha_i \cdot p(x_j | \mu_i, \Sigma_i) \right)$$

求得：

$$\mu_i = \frac{\sum_{j=1}^m \gamma_{ji} x_j}{\sum_{j=1}^m \gamma_{ji}}, \quad \Sigma_i = \frac{\sum_{j=1}^m \gamma_{ji} (x_j - \mu_i)(x_j - \mu_i)^T}{\sum_{j=1}^m \gamma_{ji}}, \quad \alpha_i = \frac{1}{m} \sum_{j=1}^m \gamma_{ji}$$

12. DBSCAN 算法

属于密度聚类算法。

基于一组“邻域”参数 $(\epsilon, \text{MinPts})$ 来刻画样本分布的紧密程度。

基本概念：

ϵ -邻域：对样本 $x_i \in D$ ，其 ϵ 邻域包含样本集 D 中与 x_i 的距离不大于 ϵ 的样本；

核心对象：若样本 x 的 ϵ 邻域至少包含 MinPts 个样本，则该样本点为一个核心对象；

密度直达：若样本 x_i 位于样本 x_j 的 ϵ 邻域中，且 x_j 是一个核心对象，则称样本 x_i 由 x_j 密度直达；

密度可达：对样本 x_i 与 x_j ，若存在样本序列 $p_1, p_2, \dots, p_n$ ，其中 $p_1 = x_i$ ， $p_n = x_j$ 且 p_{l+1} 由 p_l 密度直达，则该两样本密度可达；

密度相连：对样本 x_i 与 x_j ，若存在样本 x_k 使得两样本均由 x_k 密度可达，则称该两样本密度相连。

对“簇”的定义：由密度可达关系导出的最大密度相连样本集合。

对“簇”的形式化描述：给定领域参数，簇是满足以下性质的非空样本子集：

连接性： $x_i \in C, x_j \in C \Rightarrow x_i$ 与 x_j 密度相连。

最大性： $x_i \in C, x_i$ 与 x_j 密度可达 $\Rightarrow x_j \in C$ 。

实际上，若 x 为核心对象，由 x 密度可达的所有样本组成的集合记为 $X = \{x' \in D | x' \text{ 由 } x \text{ 密度可达}\}$ ，则 X 为满足连接性与最大性的簇。

13. AGNES 算法

属于自底向上的层次聚类算法。

首先，将样本中的每一个样本看做一个初始聚类簇，然后在算法运行的每一步中找出距离最近的两个聚类簇进行合并，该过程不断重复，直到达到预设的聚类簇的个数。

这里两个聚类簇 C_i 和 C_j 的距离，有不同的度量方式：

最小距离： $d_{min}(C_i, C_j) = \min_{x \in C_i, z \in C_j} dist(x, z)$

最大距离： $d_{max}(C_i, C_j) = \max_{x \in C_i, z \in C_j} dist(x, z)$

平均距离： $d_{avg}(C_i, C_j) = \frac{1}{|C_i||C_j|} \sum_{x \in C_i} \sum_{z \in C_j} dist(x, z)$

算法流程：

Step1: 将每个样本点作为一个簇

Step2: 合并最近的两个簇

Step3: 若所有样本点都存在与一个簇中，则停止；否则转到 Step2

十、降维与度量学习

1. k 近邻学习 (kNN)

是一种常用的监督学习方法。工作机制：

(1) 确定训练样本，以及某种距离度量。

(2) 对于某个给定的测试样本，找到训练集中距离最近的 k 个样本，对于分类问题使用“投票法”获得预测结果，对于回归问题使用“平均法”获得预测结果。还可基于距离远近进行加权平均或加权投票，距离越近的样本权重越大。

k 近邻学习没有显式的训练过程，属于“懒惰学习”。

最近邻分类 (1NN) 二分类错误率： $P(err) = 1 - \sum_{c \in \mathcal{Y}} P(c|x)P(c|z)$ ，它的泛化错误率不超过贝叶斯最优分类器错误率的两倍。

2. 多维缩放 (MDS)

假定有 m 个样本，在原始空间中的距离矩阵为 $D \in R^{m \times m}$ ，其第 i 行 j 列的元素 $dist_{ij}$ 为样本 x_i 到 x_j 的距离。目标是获得样本在 d' 维空间中的表示，且任意两个样本在 d' 维空间中的欧氏距离等于原始空间中的距离，即 $\|z_i - z_j\| = dist_{ij}$ 。

3. 线性降维方法

一般来说，欲获得低维子空间，最简单的是对原始高维空间进行线性变换。给定 d 维空间中的样本 $X = (x_1, x_2, \dots, x_m) \in R^{d \times m}$ ，变换之后得到 $d' < d$ 维空间中的样本 $Z = W^T X$ ，其中 $W \in R^{d \times d'}$ 是变换矩阵， $Z \in R^{d' \times m}$ 是样本在新空间中的表达。

4. 主成分分析 (PCA)

对于正交属性空间中的样本点，用一个超平面对所有样本进行恰当的表达。

超平面的性质包含：

(1) 最近重构性：样本点到这个超平面的距离都足够近；

(2) 最大可分性：样本点在这个超平面上的投影能尽可能分开。

可以推导得出 PCA 优化目标为：

$$\begin{aligned} \min_{\mathbf{W}} \quad & -\text{tr}(\mathbf{W}^T \mathbf{X} \mathbf{X}^T \mathbf{W}) \\ \text{s.t.} \quad & \mathbf{W}^T \mathbf{W} = \mathbf{I}. \end{aligned}$$

，其中 $\mathbf{I}$ 为单位矩阵。

5. 核化主成分分析 (KPCA)

对新样本 $\mathbf{x}$ ，其投影后的第 j ($j=1,2,\dots,d'$) 维坐标为：

$$\begin{aligned} z_j &= \mathbf{w}_j^T \phi(\mathbf{x}) = \sum_{i=1}^m \alpha_i^j \phi(\mathbf{x}_i)^T \phi(\mathbf{x}) \\ &= \sum_{i=1}^m \alpha_i^j \kappa(\mathbf{x}_i, \mathbf{x}). \end{aligned}$$

其中 α_i 已经过规范化。由该式可知，为了获得投影后的坐标，KPCA 需对所有样本求和，因此它的计算开销较大。

6. 流形学习

“流形”是在局部与欧氏空间同胚的空间，换言之，它在局部具有欧氏空间的性质，能用欧氏距离来进行距离计算。当维数被降至二维或三维时，能对数据进行可视化展示，因此流形学习也可被用于可视化。

7. 等度量映射 (Isomap)

测地线距离的计算：利用流形在局部上与欧氏空间同胚这个性质，对每个点基于欧氏距离找出其近邻点，然后就能建立一个近邻连接图，图中近邻点之间存在连接，而非近邻点之间不存在连接，于是，计算两点之间测地线距离的问题，就转变为计算近邻连接图上两点之间的最短路径问题。

8. 局部线性嵌入 (LLE)

局部线性嵌入试图保持邻域内的线性关系，并使得该线性关系在降维后的空间中继续保持。

LLE 先为每个样本 $\mathbf{x}_i$ 找到其近邻下标集合 Q_i ，然后计算出基于 Q_i 中的样本点对 $\mathbf{x}_i$ 进行线性重构的系数 w_i ：

$$\begin{aligned} \min_{w_1, w_2, \dots, w_m} \quad & \sum_{i=1}^m \left\| \mathbf{x}_i - \sum_{j \in Q_i} w_{ij} \mathbf{x}_j \right\|_2^2 \\ \text{s.t.} \quad & \sum_{j \in Q_i} w_{ij} = 1, \end{aligned}$$

令 $C_{jk} = (\mathbf{x}_i - \mathbf{x}_j)^T (\mathbf{x}_i - \mathbf{x}_k)$ ， w_{ij} 有闭式解：

$$w_{ij} = \frac{\sum_{k \in Q_i} C_{jk}^{-1}}{\sum_{l, s \in Q_i} C_{ls}^{-1}}.$$

LLE 在低维空间中保持 w_i 不变，于是 $\mathbf{x}_i$ 对应的低维空间坐标 $\mathbf{z}_i$ 可通过下式求解：

$$\min_{z_1, z_2, \dots, z_m} \sum_{i=1}^m \left\| \mathbf{z}_i - \sum_{j \in Q_i} w_{ij} \mathbf{z}_j \right\|_2^2$$

$$\min_{\mathbf{Z}} \text{tr}(\mathbf{Z} \mathbf{M} \mathbf{Z}^T),$$

$\mathbf{M} = (\mathbf{I} - \mathbf{W})^T (\mathbf{I} - \mathbf{W})$ ，可将上式重写为：

$$\text{s.t. } \mathbf{Z} \mathbf{Z}^T = \mathbf{I}.$$

9. 马氏距离

$$\text{dist}_{\text{mah}}^2(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i - \mathbf{x}_j)^T \mathbf{W}(\mathbf{x}_i - \mathbf{x}_j) = \|\mathbf{x}_i - \mathbf{x}_j\|_{\mathbf{M}}^2$$

其中， $\mathbf{M}$ 亦称“度量矩阵”，而度量学习则是对 $\mathbf{M}$ 进行学习。

10. 近邻成分分析 (NCA)

对于任意样本 $\mathbf{x}_i$ ，它对 $\mathbf{x}_l$ 分类结果影响的概率为：

$$p_{ij} = \frac{\exp(-\|\mathbf{x}_i - \mathbf{x}_j\|_{\mathbf{M}}^2)}{\sum_l \exp(-\|\mathbf{x}_i - \mathbf{x}_l\|_{\mathbf{M}}^2)}$$

当 $i=j$ 时， p_{ij} 最大。显然， $\mathbf{x}_i$ 对 $\mathbf{x}_l$ 的影响随着它们之间距离的增大而减小。

设 $\mathbf{M} = \mathbf{P}\mathbf{P}^T$ ，NCA 的优化目标：

$$\min_{\mathbf{P}} 1 - \sum_{i=1}^m \sum_{j \in \Omega_i} \frac{\exp(-\|\mathbf{P}^T \mathbf{x}_i - \mathbf{P}^T \mathbf{x}_j\|_2^2)}{\sum_l \exp(-\|\mathbf{P}^T \mathbf{x}_i - \mathbf{P}^T \mathbf{x}_l\|_2^2)}$$

可通过求解下面这个凸优化问题获得适当的度量矩阵 $\mathbf{M}$ ：

$$\begin{aligned} \min_{\mathbf{M}} \quad & \sum_{(\mathbf{x}_i, \mathbf{x}_j) \in \mathcal{M}} \|\mathbf{x}_i - \mathbf{x}_j\|_{\mathbf{M}}^2 \\ \text{s.t.} \quad & \sum_{(\mathbf{x}_i, \mathbf{x}_k) \in \mathcal{C}} \|\mathbf{x}_i - \mathbf{x}_k\|_{\mathbf{M}} \geq 1 \\ & \mathbf{M} \succeq 0 \end{aligned}$$

十一、特征选择与稀疏学习

1. 子集搜索

用贪心策略选择包含重要信息的特征子集。

前向搜索：逐渐增加相关特征

后向搜索：从完整的特征集合开始，逐渐减少特征

双向搜索：每一轮逐渐增加相关特征，同时减少无关特征

2. 子集评价

特征子集确定了对数据集的一个划分；样本标记对应着对数据集的真实划分。

通过估算上述两个划分的差异，就能对特征子集进行评价；与样本标记对应的划分的差异越小，则说明当前特征子集越好。

$$\text{信息熵定义：} \quad \text{Ent}(D) = - \sum_{k=1}^{|D|} p_k \log_2 p_k$$

$$\text{特征子集 } A \text{ 的信息增益为：} \quad \text{Gain}(A) = \text{Ent}(D) - \sum_{v=1}^V \frac{|D^v|}{|D|} \text{Ent}(D^v)$$

信息增益 $\text{Gain}(A)$ 越大，意味着特征子集 A 包含的有助于分类的信息越多。

3. 常见的特征选择方法

(1) 过滤式：先用特征选择过程过滤原始数据，再用过滤后的特征来训练模型；特征选择过程与后续学习器无关。

(2) 包裹式：包裹式选择直接把最终将要使用的学习器的性能作为特征子集的评价准

则。包裹式选择方法直接针对给定学习器进行优化，因此从最终学习器性能来看，包裹式特征选择比过滤式特征选择更好。包裹式特征选择过程中需多次训练学习器，计算开销通常比过滤式特征选择大得多。

(3) 嵌入式：嵌入式特征选择是将特征选择过程与学习器训练过程融为一体，两者在同一个优化过程中完成，在学习器训练过程中自动地进行特征选择。

4. Relief 方法

属于过滤式选择。

该方法设计了一个“相关统计量”来度量特征的重要性。该统计量是一个向量，其每个分量分别对应于一个初始特征，而特征子集的重要性则是由子集中每个特征所对应的相关统计量分量之和来决定。于是，最终只需指定一个阈值 τ ，然后选择比 τ 大的相关统计量分量所对应的特征即可；也可指定欲选取的特征个数 k ，然后选择相关统计量分量最大的 k 个特征。

猜中近邻：x的同类样本中的最近邻 $x_{i,nh}$

猜错近邻：x的异类样本中的最近邻 $x_{i,nm}$

相关统计量对应于属性 j 的分量为：

$$\delta^j = \sum_i -\text{diff}(x_i^j, x_{i,nh}^j)^2 + \text{diff}(x_i^j, x_{i,nm}^j)^2$$

多类拓展：Relief-F：

$$\delta^j = \sum_i -\text{diff}(x_i^j, x_{i,nh}^j)^2 + \sum_{l \neq k} \left(p_l \times \text{diff}(x_i^j, x_{i,l,nm}^j)^2 \right)$$

5. LVW 方法

属于包裹式选择。

LVM 在拉斯维加斯方法框架下使用随机策略来进行子集搜索，并以最终分类器的误差作为特征子集评价准则。

基本步骤：

(1) 在循环的每一轮随机产生一个特征子集

(2) 在随机产生的特征子集上通过交叉验证推断当前特征子集的误差

(3) 进行多次循环，在多个随机产生的特征子集中选择误差最小的特征子集作为最终解。

6. LASSO

$$\min_w \sum_{i=1}^m (y_i - w^\top x_i)^2 + \lambda \|w\|_1$$

使用L1范数正则化易获得稀疏解，是一种嵌入式特征选择方法。

7. 稀疏表示

将数据集看成一个矩阵，每行对应一个样本，每列对应一个特征。矩阵中有很多零元素，且非整行整列出现。

稀疏表示的优势：

(1) 文本数据线性可分；(2) 存储高效

8. 字典学习

为普通稠密表达的样本找到合适的字典，将样本转化为稀疏表示，这一过程称为字典学习。

给定数据集 $\{x_1, x_2, \dots, x_m\}$, $x_i \in \mathbb{R}^d$;

学习目标是字典矩阵 $B \in \mathbb{R}^{d \times k}$ 以及样本的稀疏表示 $\alpha_i \in \mathbb{R}^k$;

k 称为字典的词汇量，通常由用户指定;

则最简单的字典学习的优化形式为:

$$\min_{B, \alpha_i} \sum_{i=1}^m \|x_i - B\alpha_i\|_2^2 + \lambda \sum_{i=1}^m \|\alpha_i\|_1$$

9. 压缩感知

用于利用部分数据恢复全部数据。

10. 限定等距性 (RIP)

$A \in \mathbb{R}^{n \times m}$, 若存在常数 $\delta_k \in (0, 1)$ 使得对于任意向量 s 和 A 的所有子矩阵 $A_k \in \mathbb{R}^{n \times k}$ 有:

$$(1 - \delta_k) \|s\|_2^2 \leq \|A_k s\|_2^2 \leq (1 + \delta_k) \|s\|_2^2$$

则称 A 满足 k -限定等距性。

11. 矩阵补全

优化形式:

$$\begin{aligned} \min_{\mathbf{X}} \quad & \text{rank}(\mathbf{X}) \\ \text{s.t.} \quad & (\mathbf{X})_{ij} = (\mathbf{A})_{ij}, \quad (i, j) \in \Omega \end{aligned}$$

十二、计算学习理论

1. 泛化误差和经验误差

泛化误差: 分类器的期望误差 $E(h; \mathcal{D}) = P_{x \sim \mathcal{D}}(h(x) \neq y)$

经验误差: 分类器在给定样例集上的平均误差 $\hat{E}(h; \mathcal{D}) = \frac{1}{m} \sum_{i=1}^m \mathbb{I}(h(x_i) \neq y_i)$

2. 误差参数 ϵ

令 ϵ 为 $E(h)$ 的上限, 即 $E(h) \leq \epsilon$

我们通常用 ϵ 表示预先设定的学得模型所应满足的误差要求

3. 一致性

若 h 在数据集 D 上的经验误差为 0, 则称 h 与 D 一致, 否则不一致。

4. 不合

对于任意两个映射 $h_1, h_2 \in \mathcal{X} \rightarrow \mathcal{Y}$, 通过“不合”度量它们的差别:

$$d(h_1, h_2) = P_{x \sim \mathcal{D}}(h_1(x) \neq h_2(x))$$

5. 概念

概念是从样本空间 $\mathcal{X}$ 到标记空间 $\mathcal{Y}$ 的映射, 它决定示例 x 的真实标记 y 。

目标概念: 如果对所有示例 (x,y) 均有 $c(x)=y$ 成立, 则称 c 为目标概念。

概念类: 所有我们希望学得的目标概念所构成的集合称为“概念类”, 用符号 $\mathcal{C}$ 表示。

6. 假设空间

给定学习算法 $\mathcal{L}$, 它所考虑的所有可能概念的集合, 用符号 $\mathcal{H}$ 表示。

学习过程可以视为 $\mathcal{L}$ 在 $\mathcal{H}$ 中进行的搜索过程。

7. 可分的与不可分的

若目标概念 $c \in \mathcal{H}$, 即 $\mathcal{H}$ 中存在假设能将所有的示例完全正确分开(按照与真实标记一致的方式), 则称该问题对学习算法是“可分的”, 也称“一致的”。反之, 则不可分。

8. 概率近似正确 (PAC)

我们希望以比较大的把握学得比较好的模型, 即以较大概率学得误差满足预设上限的模型。

PAC 辨识: 对 $0 < \epsilon, \delta < 1$, 所有 $c \in \mathcal{C}$ 和分布 D , 若存在学习算法 $\mathcal{L}$, 其输出假设 $h \in \mathcal{H}$ 满足 $P(E(h) \leq \epsilon) \geq 1 - \delta$, 则称学习算法 $\mathcal{L}$ 能从假设空间 $\mathcal{H}$ 中 PAC 辨识概念类 $\mathcal{C}$ 。

9. 样本复杂度

满足 PAC 学习算法 $\mathcal{L}$ 所需的 $m \geq \text{poly}(1/\epsilon, 1/\delta, \text{size}(x), \text{size}(c))$ 中最小的 m , 称为学习算法 $\mathcal{L}$ 的样本复杂度。

10. PAC 学习的意义

给出了一个抽象地刻画机器学习能力的框架, 基于这个框架可以对很多重要问题进行理论探讨。把对复杂算法的时间复杂度的分析转为对样本复杂度的分析。

11. 经验风险最小化原则 (ERM):

$$\hat{E}(h) = \min_{h' \in \mathcal{H}} \hat{E}(h')$$

12. 增长函数

$$\Pi_{\mathcal{H}}(m) = \max_{\{x_1, x_2, \dots, x_m\} \subseteq \mathcal{X}} |\{(h(x_1), h(x_2), \dots, h(x_m)) \mid h \in \mathcal{H}\}|$$

13. 对分

对二分类问题来说, $\mathcal{H}$ 中的假设对 D 中示例赋予标记的每种可能结果称为对 D 的一种“对分”。

14. 打散

若假设空间 $\mathcal{H}$ 能实现示例集 D 上的所有对分, 则称示例集 D 能被假设空间“打散”。

15. VC 维

假设空间 $\mathcal{H}$ 的 VC 维是能被 $\mathcal{H}$ 打散的最大示例集的大小，即：

$$VC(\mathcal{H}) = \max\{m : \prod_{\mathcal{H}}(m) = 2^m\}$$

$VC(\mathcal{H})=d$ 意味着存在一个大小为 d 的示例集能被 $\mathcal{H}$ 打散，并且所有大小超过 d 的示例集都无法被孔打散。

十三、半监督学习

1. 未标记样本的假设

聚类假设：假设数据存在簇结构，同一簇的样本属于同一类别。

流形假设：假设数据分布在一个流形结构上，邻近的样本具有相似的输出值。

2. 生成式方法

假设样本由高斯混合模型生成，且每个类别对应一个高斯混合成分：

$$p(x) = \sum_{i=1}^k \alpha_i \cdot p(x | \mu_i, \Sigma_i), \text{ 其中, } \alpha_i \geq 0, \sum_{i=1}^k \alpha_i = 1.$$

高斯混合的参数估计可以采用 EM 算法求解，迭代更新式如下：

E 步：根据当前模型参数计算未标记样本属于各高斯混合成分的概率：

$$\gamma_{ji} = \frac{\alpha_i \cdot p(x_j | \mu_i, \Sigma_i)}{\sum_{i=1}^N \alpha_i \cdot p(x_j | \mu_i, \Sigma_i)}$$

M 步：基于 γ_{ji} 更新模型参数：

$$\begin{aligned} \mu_i &= \frac{1}{\sum_{x_j \in D_u} \gamma_{ji} + l_i} (\sum_{x_j \in D_u} \gamma_{ji} x_j + \sum_{(x_i, y_i) \in D_l \wedge y_j = i} x_j) \\ \Sigma_i &= \frac{1}{\sum_{x_j \in D_u} \gamma_{ji} + l_i} (\sum_{x_j \in D_u} \gamma_{ji} (x_j - \mu_i)(x_j - \mu_i)^T \\ &\quad + \sum_{(x_i, y_i) \in D_l \wedge y_j = i} (x_j - \mu_i)(x_j - \mu_i)^T) \\ \alpha_i &= \frac{1}{m} (\sum_{x_j \in D_u} \gamma_{ji} + l_i) \end{aligned}$$

此类方法简单、易于实现，在有标记数据极少的情形下往往比其他方法性能更好。然而，此类方法有一个关键：模型假设必须准确，即假设的生成式模型必须与真实数据分布吻合；否则利用未标记数据反而会显著降低泛化性能。

3. 半监督 SVM

TSVM 采用局部搜索来迭代地寻找近似解，优化目标：

$$\begin{aligned} \min_{w, b, \xi} \quad & \frac{1}{2} \|w\|_2^2 + C_l \sum_{i=1}^l \xi_i + C_u \sum_{i=l+1}^m \xi_i \\ \text{s.t.} \quad & y_i(w^\top x_i + b) \geq 1 - \xi_i, \quad i = 1, \dots, l, \\ & \hat{y}_i(w^\top x_i + b) \geq 1 - \xi_i, \quad i = l+1, \dots, m, \\ & \xi_i \geq 0, \quad i = 1, \dots, m, \end{aligned}$$

显然，搜寻标记指派可能出错的每一对未标记样本进行调整，仍是一个涉及巨大计算开销的大规模优化问题。因此，半监督 SVM 研究的一个重点是如何设计出高效的优化求解策略。

4. 图半监督学习

“能量函数”：

$$\begin{aligned}
E(f) &= \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m (\mathbf{W})_{ij} (f(\mathbf{x}_i) - f(\mathbf{x}_j))^2 \\
&= \frac{1}{2} \left(\sum_{i=1}^m d_i f^2(\mathbf{x}_i) + \sum_{j=1}^m d_j f^2(\mathbf{x}_j) - 2 \sum_{i=1}^m \sum_{j=1}^m (\mathbf{W})_{ij} f(\mathbf{x}_i) f(\mathbf{x}_j) \right) \\
&= \sum_{i=1}^m d_i f^2(\mathbf{x}_i) - \sum_{i=1}^m \sum_{j=1}^m (\mathbf{W})_{ij} f(\mathbf{x}_i) f(\mathbf{x}_j) \\
&= \mathbf{f}^T (\mathbf{D} - \mathbf{W}) \mathbf{f}, \tag{13}
\end{aligned}$$

单分类问题的“单步式”标记传播方法：

$$\begin{aligned}
\mathbf{f}_u &= (\mathbf{D}_{uu} (\mathbf{I} - \mathbf{D}_{uu}^{-1} \mathbf{W}_{uu}))^{-1} \mathbf{W}_{ul} \mathbf{f}_l \\
&= (\mathbf{I} - \mathbf{D}_{uu}^{-1} \mathbf{W}_{uu})^{-1} \mathbf{D}_{uu}^{-1} \mathbf{W}_{ul} \mathbf{f}_l \\
&= (\mathbf{I} - \mathbf{P}_{uu})^{-1} \mathbf{P}_{ul} \mathbf{f}_l
\end{aligned}$$

多分类问题的“迭代式”标记传播方法：

$$\mathbf{F}^* = \lim_{t \rightarrow \infty} \mathbf{F}(t) = (\mathbf{I} - \alpha \mathbf{S})^{-1} \mathbf{Y}$$

图半监督学习方法在概念上相当清晰，且易于通过对所涉矩阵运算的分析来探索算法性质。但此类算法的缺陷也相当明显，首先是其存储开销高。另一方面，由于构图过程仅能考虑训练样本集，难以判知新样本在图中的位置，因此，在接收到新样本时，或是将其加入原数据集对图进行重构并重新进行标记传播，或是需引入额外的预测机制。

5. 基于分歧的方法

协同训练是基于分歧的方法的重要代表。协同训练正是很好地利用了多视图的“相容互补性”。假设数据拥有两个“充分”且“条件独立”视图。

基于分歧的方法只需采用合适的基学习器，就较少受到模型假设、损失函数非凸性和数据规模问题的影响，学习方法简单有效、理论基础相对坚实、适用范围较为广泛。为了使用此类方法，需能生成具有显著分歧、性能尚可的多个学习器，但当有标记样本很少、尤其是数据不具有多视图时，要做到这一点并不容易。

6. 半监督聚类

聚类任务中获得的监督信息大致有两种类型：

(1) “必连”与“勿连”约束，前者是指样本必属于同一个簇，后者则是指样本必不属于同一个簇；

(2) 少量的有标记样本。

约束 k 均值算法（利用第一种信息）：该算法是 k 均值算法的扩展，它在聚类过程中要确保“必连”关系集合与“勿连”关系集合中的约束得以满足，否则将返回错误提示。

约束种子 k 均值算法（利用第二种信息）：直接将少量有标记样本作为“种子”，用它们初始化 k 均值算法的 k 个聚类中心，并且在聚类簇迭代更新过程中不改变种子样本的簇隶属关系。

十四、概率图模型

1. 概率模型

概率模型提供了一种描述框架,将学习任务归结为计算变量的概率分布,在概率模型中,利用已知变量推测未知变量的分布称为“推断”,其核心是如何基于可观测变量推测出未知变量的条件分布。

2. 概率图模型

概率图模型是一类用图来表达变量相关关系的概率模型。

结点: 随机变量 (集合)

边: 变量间的概率相关关系

分类: 有向图 (贝叶斯网); 无向图 (马尔可夫网)

3. 隐马尔可夫模型 HMM

组成: (1) 状态变量: $\{y_1, y_2, \dots, y_n\}$ 通常假定是隐藏的, 不可被观测的。

(2) 观测变量: $\{x_1, x_2, \dots, x_n\}$ 表示第 i 时刻的观测值集合。

t 时刻的状态 y 仅依赖于 $t-1$ 时刻状态 y , 与其余 $t-2$ 个状态无关。

所有变量的联合概率分布:

$$P(x_1, y_1, \dots, x_n, y_n) = P(y_1)P(x_1 | y_1) \prod_{i=2}^n P(y_i | y_{i-1})P(x_i | y_i)$$

HMM 基本组成: 确定一个 HMM 需要三组参数 $\lambda = [A, B, \pi]$

(1) 状态转移概率: 模型在各个状态间转换的概率

(2) 输出观测概率: 模型根据当前状态获得各个观测值的概率

(3) 初始状态概率: 模型在初始时刻各个状态出现的概率

观测序列:

(1) 设置 $t = 1$, 并根据初始状态 π 选择初始状态 y_t

(2) 根据状态 y_t 和输出观测概率 B 选择观测变量取值 x_t

(3) 根据状态 y_t 和状态转移矩阵 A 转移模型状态, 即确定 y_{t+1}

(4) 若 $t < n$, 设置 $t = t+1$, 并转到 (2) 步, 否则停止

HMM 的基本问题:

(1) 评估模型和观测序列之间的匹配程度: 有效计算其产生观测序列的概率 $P(x|\lambda)$

(2) 根据观测序列“推测”隐藏的模型状态 $y = \{y_1, y_2, \dots, y_n\}$

(3) 参数学习: 如何调整模型参数 $\lambda = [A, B, \pi]$ 以使得该序列出现的概率 $P(x|\lambda)$ 最大

4. 马尔可夫随机场 (MRF)

分布形式化: 使用基于极大团的势函数 (因子)

极大团: 对于图中结点的一个子集, 若其中任意两结点间都有边连接, 则称该结点子集为一个“团”。若一个团中加入另外任何一个结点都不再形成团, 则称该团为“极大团”。

假设所有极大团构成的集合为 C^* , ψ_Q 是于团 Q 对应的势函数, 联合概率定义:

$$P(x) = \frac{1}{Z^*} \prod_{Q \in C^*} \psi_Q(x_Q), \text{ 其中, } Z^* \text{ 是规范化因子 } Z^* = \sum_x \prod_{Q \in C^*} \psi_Q(x_Q)$$

5. 分离集

若从结点集 A 中的结点到 B 中的结点都必须经过结点集 C 中的结点, 则称结点集 A , B 被结点集 C 分离, 称 C 为分离集。

6. 全局马尔可夫性

在给定分离集的条件下，两个变量子集条件独立。

7. 局部马尔可夫性

在给定邻接变量的情况下，一个变量条件独立于其它所有变量。

8. 成对马尔可夫性

在给定所有其他变量的情况下，两个非邻接变量条件独立。

9. 势函数 $\psi_Q(\mathbf{x}_Q)$

作用是定量刻画变量集 $\mathbf{x}_Q$ 中变量的相关关系，应是非负函数，且在所偏好的变量取值上有较大的函数值。

为了满足非负性，指数函数常被用于定义势函数，即：

$$\psi_Q(\mathbf{x}_Q) = e^{-H_Q(\mathbf{x}_Q)}$$

其中， $H_Q(\mathbf{x}_Q)$ 是一个定义在变量 $\mathbf{x}_Q$ 上的实值函数，常见形式为：

$$H_Q(\mathbf{x}_Q) = \sum_{u,v \in Q, u \neq v} \alpha_{uv} x_u x_v + \sum_{v \in Q} \beta_v x_v$$

其中， α_{uv} 和 β_v 是参数，上式第一项考虑每一对结点的关系，第二项考虑单结点。

10. 链式条件随机场 (CRF)

条件概率：

$$P(\mathbf{y} | \mathbf{x}) = \frac{1}{Z} \exp \left(\sum_j \sum_{i=1}^{n-1} \lambda_j t_j(y_{i+1}, y_i, \mathbf{x}, i) + \sum_k \sum_{i=1}^n \mu_k s_k(y_i, \mathbf{x}, i) \right)$$

其中， $t_j(y_i, y_{i+1}, \mathbf{x}, i)$ 是定义在观测序列的两个相邻标记位置上的转移特征函数，用于刻画相邻标记变量之间的相关关系以及观测序列对它们的影响；

$s_k(y_i, \mathbf{x}, i)$ 是定义在观测序列的标记位置 i 上的状态特征函数，用于刻画观测序列对标记变量的影响。

λ_j, μ_k 为参数， Z 为规范化因子。

11. 模型推断

边际分布：
$$p(\mathbf{x}_E) = \sum_F p(\mathbf{x}_F, \mathbf{x}_E)$$

12. 精确推断

(1) 变量消去：

$m_{ij}(x_j)$ 是求加过程中的中间结果，下标 i 表示此项是对 x 求加的结果，下标 j 表示此项中剩下的其它变量；显然， $m_{ij}(x_j)$ 是关于 x_j 的函数。

(2) 信念传播：

信念传播算法中，一个结点仅在接收到来自其它所有结点的消息后才能向另一个结点发送消息，且结点的边际分布正比于它所接收的消息的乘积：

$$p(x_i) \propto \prod_{k \in n(i)} m_{ki}(x_i)$$

若图中没有环，则信念传播算法经过两个步骤即可完成所有消息传递，进而能计算所有变量上的边际分布：

指定一个根结点，从所有叶结点开始向根结点传递消息，直到根结点收到所有邻接结点的消息；

从根结点开始向叶结点传递消息，直到所有叶结点均收到消息。

13. 近似推断

精确推断方法需要很大的计算开销，因此在现实应用中近似推断方法更为常用。

近似推断方法大致可以分为两类：

(1) 采样法：通过使用随机化方法完成近似，如 MCMC 采样

(2) 变分推断：使用确定性近似完成近似推断

14. 采样法

问题的关键变成了如何取样，即如何高效地从图模型所描述的概率分布中获取样本。

15. 马尔可夫链蒙特卡罗 (MCMC)

马尔可夫链蒙特卡罗 (MCMC) 是图模型中最常用的采样技术。

给定连续变量 $x \in X$ 的概率密度函数 $p(x)$ ， x 在区间 A 中的概率为：

$$P(A) = \int_A p(x) dx$$

若有函数 $f: X \rightarrow R$ ，可计算 $f(x)$ 的期望：

$$p(f) = \mathbb{E}_p[f(X)] = \int_x f(x)p(x)dx,$$

MCMC 先构造出服从 p 分布的独立同分布随机变量 $x_1, x_2, \dots, x_N$ ，再得到无偏估计：

$$\tilde{p}(f) = \frac{1}{N} \sum_{i=1}^N f(x_i)$$

MCMC 算法的关键在于通过“构造平稳分布为 p 的马尔可夫链”来产生样本。

判定马尔可夫链的平稳态：

假定马尔可夫链 T 的状态转移概率为 $T(x' | x)$ ， t 时刻状态的分布为 $p(x^t)$ ，则若在某个时刻马尔可夫链满足平稳条件：

$$p(x^t)T(x^{t-1} | x^t) = p(x^{t-1})T(x^t | x^{t-1})$$

则 $p(x)$ 是该马尔可夫链的平稳分布，且马尔可夫链在满足该条件时已经收敛到平稳状态。

16. MH 算法

MH 算法是 MCMC 算法的代表之一。基于“拒绝采样”逼近平稳分布。

算法每次根据上一轮采样结果 x^{t-1} 来采样获得候选状态样本 x^* ，但这个样本会以一定概率被拒绝。

$$p(x^{t-1})Q(x^* | x^{t-1})A(x^* | x^{t-1}) = p(x^*)Q(x^{t-1} | x^*)A(x^{t-1} | x^*)$$


为了达到平稳状态，只需要将接受率设置为：

$$A(x^* | x^{t-1}) = \min \left(1, \frac{p(x^*)Q(x^{t-1} | x^*)}{p(x^{t-1})Q(x^* | x^{t-1})} \right)$$

17. 变分推断

变分推断通过使用已知简单分布来逼近需推断的复杂分布,并通过限制近似分布的类型,从而得到一种局部最优、但具有确定解的近似后验分布。

盘式记法:



所有能观察到的变量 x 的联合分布概率密度函数:

$$p(\mathbf{x} | \Theta) = \prod_{i=1}^N \sum_{\mathbf{z}} p(x_i, \mathbf{z} | \Theta)$$

对应的对数似然:

$$\ln p(\mathbf{x} | \Theta) = \sum_{i=1}^N \ln \left\{ \sum_{\mathbf{z}} p(x_i, \mathbf{z} | \Theta) \right\}$$

推断和学习任务主要是由观察变量 x 来估计隐变量 z 和分布参数 Θ , 即求解 $P(z | x, \Theta)$ 和 Θ 。

可使用 EM 算法最大化对数似然。

18. 话题模型

话题模型是一类生成式有向图模型, 主要用来处理离散型的数据集合 (如文本集合)。
作为一种非监督产生式模型, 话题模型能够有效利用海量数据发现文档集合中隐含的语义。
隐狄里克雷分配模型 (LDA) 是话题模型的典型代表。

19. LDA 的基本单元

(1) 词: 待处理数据中的基本离散单元

(2) 文档: 待处理的数据对象, 由词组成, 词在文档中不计顺序。数据对象只要能用“词袋”表示就可以使用话题模型

(3) 话题: 表示一个概念, 具体表示为一系列相关的词, 以及它们在该概念下出现的概率

模型参数估计:

$$LL(\alpha, \eta) = \sum_{t=1}^T \ln p(w_t | \alpha, \eta)$$

模型推断:

$$p(\mathbf{z}, \beta, \Theta | \mathbf{W}, \alpha, \eta) = \frac{p(\mathbf{W}, \mathbf{z}, \beta, \Theta | \alpha, \eta)}{p(\mathbf{W} | \alpha, \eta)}$$

十五、规则学习

1. 序贯覆盖

在训练集上每学到一条规则，就将该规则覆盖的样例去除，然后以剩下的样例组成训练集重复上述过程（分治策略）

十六、强化学习

1. 马尔可夫决策过程

- (1) 机器所处的环境 E ;
- (2) 状态空间 $\{X:x \in X\}$ 是机器感知到的环境的描述;
- (3) 智能体能采取的行为空间 A
- (4) 潜在的状态转移(概率)函数 $P:X \times A \times X \rightarrow \mathbb{R}$
- (5) 潜在的奖赏函数 $R:X \times A \times X \rightarrow \mathbb{R}$ (或 $R:X \times X \rightarrow \mathbb{R}$)
- (6) 策略 $\pi:X \rightarrow A$ (或 $\pi:X \times A \rightarrow \mathbb{R}$)

2. 强化学习的目标

机器通过在环境中不断尝试从而学到一个策略 π ，使得长期执行该策略后得到的期望累积奖赏最大。

3. 强化学习面临的主要困难

- 探索-利用窘境:
- 探索：估计不同动作的优劣（奖赏期望的大小）
- 利用：选择当前最优的动作

4. ϵ -贪心

- 以 ϵ 的概率探索：均匀随机选择一个动作
- 以 $1-\epsilon$ 的概率利用：选择当前平均奖赏最高的动作

5. softmax

- 基于当前已知的动作平均奖赏来对探索与利用折中
- 若某个动作当前的平均奖赏越大，则它被选择的概率越高
- 概率分配使用 Boltzmann 分布：

$$P(k) = \frac{e^{\frac{Q(k)}{\tau}}}{\sum_{i=1}^K e^{\frac{Q(i)}{\tau}}}$$

其中， $Q(i)$ 记录当前动作的平均奖赏。 τ 为折中参数。

6. 有模型学习

$E = \langle X, A, P, R \rangle$, X, A, P, R 均已知

给定 π ，状态-动作值函数的计算：通过值函数来表示：

$$\begin{cases} Q_T^\pi(x, a) = \sum_{x' \in X} P_{x \rightarrow x'}^a \left(\frac{1}{T} R_{x \rightarrow x'}^a + \frac{T-1}{T} V_{T-1}^\pi(x') \right) \\ Q_\gamma^\pi(x, a) = \sum_{x' \in X} P_{x \rightarrow x'}^a \left(R_{x \rightarrow x'}^a + \gamma V_\gamma^\pi(x') \right). \end{cases}$$

7. 策略迭代

(1) 随机策略作为初始策略

(2) 策略评估、策略改进

(3) 直到策略收敛，否则重复执行第 2 步。

缺点：每次改进策略后都要重新评估策略，计算开销较大

8. 免模型学习

转移概率，奖赏函数未知，甚至环境中的状态数目也未知，假定状态空间有限。

9. 蒙特卡罗强化学习

采样轨迹，用样本均值近似期望。

策略评估：蒙特卡罗法：

从某状态出发，执行某策略；对轨迹中出现的每对状态-动作，记录其后的奖赏之和；

采样多条轨迹，每个状态-动作对的累积奖赏取平均。

策略改进：换入当前最优动作

问题：轨迹的单一性

解决方法： ϵ -贪心法

缺点：低效：求平均时以“批处理式”进行；在一个完整的采样轨迹完成后才对状态-动作值函数进行更新。

克服方法：时序差分 (TD) 学习

10. 时序差分学习 (TD)

增量式地进行状态-动作值函数更新

ϵ -贪心法：(1) 同策略：Sarsa 算法 (2) 异策略：Q-学习

11. 值函数近似

用于处理连续状态空间。

线性近似：将值函数表达为状态的线性函数： $V_{\theta}(x) = \theta^T x$ ，其中， θ^T 是参数向量， x 是状态向量。

非线性近似：核函数；神经网络

12. 直接模仿学习

(1) 利用专家的决策轨迹，构造数据集 D ：状态作为特征，动作作为标记；

(2) 利用数据集 D ，使用分类/回归算法即可学得策略；

(3) 将学得策略作为初始策略；

(4) 策略改进，从而获得更好的策略。

13. 逆强化学习

基本思想：寻找某种奖赏函数使得范例数据是最优的，然后即可使用这个奖赏函数来训练强化学习策略