

自然语言处理

作业一

一. (20 points) NLP 基础

1. RNN 和 Transformer 在处理序列数据时的主要机制是什么? (3 points)
2. 为什么 Transformer 在处理长序列时通常优于传统 RNN (如 LSTM/GRU)? 给出具体解释。 (3 points)
3. 从计算效率角度, 分析 Transformer 相对于 RNN 的优势和劣势。 (4 points)
4. 分别针对 RNN 和 Transformer, 各举一个更适合的应用场景, 并说明原因。 (4 points)
5. 单塔模型和双塔模型各自的优缺点是什么? (3 points)
6. BLEU 作为度量指标有哪些缺陷? (3 points)

二. (35 points) Transformer

1. 一层 Transformer 中都有哪些模块包含参数? (2 points)
2. 给定如下 Transformer, 给定维度 $d_{model} = 512$, FFN 中间层维度 $d_{ff} = 2048$, 头数 $h = 8$, 头维 $d_q = d_k = d_v = 64$, 求 Transformer 一层的参数量有多少。 (3 points)
3. 通常, 我们可以将 Transformer 的 FFN 表示成如下形式:

$$FF(\mathbf{x}) = f(\mathbf{x} \cdot W_1 + b_1) \cdot W_2 + b_2$$

在 Memory Network(MN) 中, 一个 neural memory 中有 d_m 个 key-value pair, 我们称之为 memory, 每一个键我们用 $k_i \in \mathbb{R}^d$ 表示, 总共我们可以得到一个参数矩阵 $K \in \mathbb{R}^{d_m \times d}$ 。同理, 我们可以得到

值的参数矩阵 $V \in \mathbb{R}^{d_m \times d}$ 。给定一个输入向量 $\mathbf{x} \in \mathbb{R}^d$ ，我们可以计算 key 的分布，然后计算输出：

$$p(k_i | x) \propto \exp(\mathbf{x} \cdot \mathbf{k}_i)$$

$$MN(\mathbf{x}) = \sum_{i=1}^{d_m} p(k_i | \mathbf{x}) \mathbf{v}_i$$

上述过程，写成矩阵的形式为：

$$MN(\mathbf{x}) = \text{softmax}(\mathbf{x} \cdot \mathbf{K}^\top) \cdot V$$

因此，忽略 FFN 中的偏置后，我们可以从另外一个角度看待 FFN。Transformer 中的 FFN 可以看做是一种储存了知识的 memory network。请推导出他们二者之间的联系。(10 points)

4. Transformer 架构具有多头注意力机制。他们将其描述为一种拼接过程，用于在每一层中并行地为多个“头” ($\text{head}_j \in \mathbb{R}^d, j \leq J$) 执行注意力函数。核心公式如下：

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) W^O$$

$$\text{where head}_j = \text{Attention}(QW_j^Q, KW_j^K, VW_j^V)$$

实际上，我们也可以将多头注意力的结果看成是多个头的结果的累加，即每个 head_j 与矩阵中一部分 W^O 乘积并累加的结果。请你尝试推导。[提示：从分块矩阵的角度出发] (10 points)

5. 忽略 Transformer 架构中的 LayerNorm，用 MHA 表示多头注意力机制，FFN 表示前馈神经网络，给定 Transformer 第 l 层输入 x^l ，那么第 l 层的输出是什么？答案示例： $MHA(x^l) + FFN(x^l)$ 。[提示：不要忘记残差流] (10 points)

三. (20 points) 神经网络和注意力机制的实现

给定一个批次的序列输入 `input = torch.Tensor(32, 100, 500)`，其中 32 表示批次大小，100 表示序列长度，而 500 表示维度数。

1. 请学习 pytorch 中关于卷积层，LSTM 以及 Transformer 编码器的接口，即 `nn.LSTM()` 等。请依次定义上面三个神经网络让其接受 `input` 为输入，输出一个跟 `input` 同等形状的 tensor。(10 points)
2. 请实现任意两种注意力机制，对该序列输入进行聚合，得到一个新的聚合后的 tensor，该 tensor 的形状为 (32,500)。(10 points)

四. (25 points) 词嵌入

本题探索词嵌入并且用词嵌入进行文本分类。

1. 请解释 Word2vec 中 CBOW 和 Skip-gram 两种模型的区别，并说明各自的适用场景。(5 points)
2. 请基于词嵌入（如 Glove 50d）和机器学习分类器（如 SVM 等）对 AG news 数据集进行文本分类。请提供代码并且给出在测试集上的分类结果。代码应包括加载词嵌入，文本到词嵌入的映射，训练分类器。如果受限于设备，可以使用一部分数据集进行训练。(12 points)
3. 在仍然只使用该词嵌入和分类器的情况下，有没有什么方法可以提升性能并且验证。(8 points)