

# 自然语言处理

2025 年春季

## 作业四

### I. FlashAttention (23 points)

给定一个 Transformer 模型, 其注意力模块的注意力头数为 16, 每个注意力头维度为 64. 给定一个输入, 其序列长度为 2048, batch size 为 4. 模型参数和输入张量的数据类型为 `float16` (即每个元素占用 2 字节).

1. (2 + 2 points) 标准注意力实现需要显式构造注意力得分矩阵  $\mathbf{QK}^\top$ . 在上述的场景下, 存储该矩阵的张量 `shape` 是什么? 存储这一张量需要多少显存开销 (单位: MB)?
2. (4 + 5 points) FlashAttention 采用块处理机制来避免显式存储整个  $\mathbf{QK}^\top$  以优化显存使用. 在上述的场景下, 若块大小为 128, 存储该块的张量 `shape` 是什么? 显存开销是多少 (单位: MB)?
3. (5 + 5 points) 在 FlashAttention 的计算过程中, 峰值显存开销来自对以下几个张量的临时存储: (a) Query 块, (b) Key 块, (c) 注意力得分矩阵, (d) Value 块, 和 (e) 输出块. 在上述场景下 (块大小同样为 128), 这些张量的 `shape` 是什么? 总的峰值显存开销为多少 (单位: MB)?

### II. 旋转位置编码 (24 points)

旋转位置编码 (RoPE) 使用对角分块矩阵

$$\mathbf{R}_n = \begin{pmatrix} \mathbf{R}_0 & \mathbf{0} & \cdots & \mathbf{0} \\ \mathbf{0} & \mathbf{R}_1 & \cdots & \mathbf{0} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{0} & \mathbf{0} & \cdots & \mathbf{R}_{d/2-1} \end{pmatrix}_{d \times d}, \text{ where } \mathbf{R}_i = \begin{bmatrix} \cos n\theta_i & -\sin n\theta_i \\ \sin n\theta_i & \cos n\theta_i \end{bmatrix}, \quad (1)$$

为 attention 机制中的 query 和 key 注入绝对位置信息, 即  $(\mathbf{R}_m \mathbf{q})^\top (\mathbf{R}_n \mathbf{k})$ .

1. (7 points) RoPE 通过绝对位置编码的方式实现了相对位置编码. 请证明 RoPE 的绝对位置信息注入方式具有相对位置编码的效果, 即  $(\mathcal{R}_m \mathbf{q})^\top (\mathcal{R}_n \mathbf{k}) = \mathbf{q}^\top \mathcal{R}_{n-m} \mathbf{k}$ .
2. (6 points) 由于  $\mathcal{R}_n$  的稀疏性, 可以使用逐元素相乘 (element-wise multiplication) 的方式替代矩阵乘法以节省计算资源消耗. 请写出  $\mathcal{R}_n \mathbf{k}$  对应的逐元素相乘形式的表达式. (可以使用符号  $\otimes$  表示逐元素相乘)
3. (12 points) RoPE 具有语义聚合特性, 即语义相似的 token 会被分配与距离无关的更大的注意力. 为形式化描述这一特性, 我们作出以下假设和定义:
  - (a) 假设  $\mathbf{q}$  的各个分量独立同分布, 且均服从均值为  $\mu$ , 方差为  $\sigma$  的分布;
  - (b) 定义一个与  $\mathbf{q}$  语义相似的 key 为  $\tilde{\mathbf{k}} = \mathbf{q} + \boldsymbol{\epsilon}$ , 其中  $\boldsymbol{\epsilon}$  为均值为 0, 方差为 1 的扰动;
  - (c) 定义一个与  $\mathbf{q}$  语义不相似的 key  $\mathbf{k}$ , 其与  $\mathbf{q}$  独立同分布, 即  $\mathbf{k}$  的各个分量独立同分布, 且均服从均值为  $\mu$ , 方差为  $\sigma$  的分布.

基于上述假设和定义, RoPE 的语义聚合特性可以表示为  $\mathbb{E}_{\mathbf{q}, \mathbf{k}, \boldsymbol{\epsilon}} [\mathbf{q}^\top \mathcal{R}_{n-m} \tilde{\mathbf{k}} - \mathbf{q}^\top \mathcal{R}_{n-m} \mathbf{k}] \geq 0$ , 即从统计意义上看, 语义相似的 token 之间的注意力  $\mathbf{q}^\top \mathcal{R}_{n-m} \tilde{\mathbf{k}}$  比语义不相似的 token 之间的注意力  $\mathbf{q}^\top \mathcal{R}_{n-m} \mathbf{k}$  更大. 请证明

$$\mathbb{E}_{\mathbf{q}, \mathbf{k}, \boldsymbol{\epsilon}} [\mathbf{q}^\top \mathcal{R}_{n-m} \tilde{\mathbf{k}} - \mathbf{q}^\top \mathcal{R}_{n-m} \mathbf{k}] \geq 0 \quad \text{s.t.} \quad \sum_{i=0}^{d/2-1} \cos(n-m)\theta_i \geq 0. \quad (2)$$

### III. LoRA (23 points)

对于预训练权重矩阵  $\mathbf{W}_0 \in \mathbb{R}^{m \times n}$ , LoRA 不直接微调权重矩阵, 而是对权重增量做低秩分解假设  $\mathbf{W} = \mathbf{W}_0 + \mathbf{A}\mathbf{B}$ , 其中,  $\mathbf{A} \in \mathbb{R}^{m \times r}$ ,  $\mathbf{B} \in \mathbb{R}^{r \times n}$ .

1. (5 points) 若  $m = n = 768$ ,  $r = 8$ , 请计算相比全参数微调, LoRA 节省了多少参数.
2. (18 points) 请基于 PyTorch 的 `nn.Linear`, 实现支持 LoRA 的线形层 `LoraLinear` 并给出代码. 要求: (a) 类名为 `LoraLinear`, 继承自 `nn.Linear`; (b) 对  $\mathbf{A}$  和  $\mathbf{B}$  的初始化; (c) `forward` 函数实现  $\mathbf{x}\mathbf{W} = \mathbf{x}\mathbf{W}_0 + \mathbf{x}\mathbf{A}\mathbf{B}$ ; (d) 实现参数合并功能, 即将  $\mathbf{A}$  和  $\mathbf{B}$  融合进入  $\mathbf{W}_0$  中.

## IV. 跨语言问答系统设计 (18 points)

你需要为一种语料资源极少的语言 (如: 约鲁巴语) 开发问答系统. 该语言缺乏问答标注数据, 仅有 (a) 少量未标注的约鲁巴语文本, (b) 少量英语-约鲁巴语平行句对, 和 (c) 英语大规模问答数据 (如: SQuAD). 系统的目标功能是: 输入英文问题, 模型从约鲁巴语文章中抽取答案作为回答.

**(20 points)** 请结合翻译语言模型 (TLM) 或零样本迁移等技术, 给出训练这一模型的流程. 需要综合考虑包括数据构造与预处理, 训练目标及策略, 以及模型微调等方面可能遇到的问题.

## V. LLMs 评估 (12 points)

大语言模型常被用作“自动评分器”来评估其他模型的文本生成质量 (如: 使用 GPT-4 为 LLaMa-3.1 的生成结果打分). 请回答以下问题:

1. **(4 points)** 简要分析该方法的优势与局限性, 特别是在数学推理任务和长文本生成任务中的表现.
2. **(8 points)** 请提出一个改进方案, 能够提升模型作为评估器的准确性和可靠性. 可以从 prompt 工程, 任务分解, 答案格式规范化等角度切入, 并说明你会如何评估你提出方法的有效性.