

自然语言处理 (2025 春季学期)

一、绪 论



参考书籍

■ 自然语言处理：基于预训练模型的方法

- 车万翔 郭江 崔一鸣 著
- 电子工业出版社、中国工信出版集团
- 出版日期：2021-7
- ISBN: 978-7-121-41512-8
- RMB 118 元





参考书籍

■ 自然语言处理导论

- 张奇 桂韬 黄萱菁 著
- 电子工业出版社、中国工信出版集团
- 出版日期：2023-8
- ISBN: 978-7-121-46032-6
- RMB 268 元





参考资料

■ 斯坦福大学 CS224N课程

Natural Language Processing with Deep Learning

CS224N

Stanford School of Engineering

Investigate the fundamental concepts and ideas in natural language processing (NLP), and gain a thorough introduction to cutting-edge neural networks for NLP. You will develop an in-depth understanding of both the algorithms available for processing linguistic information and the underlying computational properties of natural languages. The focus is on deep learning approaches: implementing, training, debugging, and extending neural network models for a variety of language understanding tasks. You will progress from word-level and syntactic processing to coreference, question answering and machine translation. For your final project, you will apply a complex neural network model to a large-scale NLP problem.



南京大学
NANJING UNIVERSITY



大纲

■ 基本概念

- 自然语言处理简史
- 自然语言处理的主要研究内容
- 自然语言处理的主要难点

■ 基本范式



什么是自然语言处理？

自然语言处理 (Natural Language Processing, NLP) 旨在探索实现人与计算机之间用**自然语言进行有效交流**的理论与方法。

--- 《大规模文本处理》

能够理解自然语言的意义

--- 自然语言理解 (Natural Language Understanding, NLU)


以自然语言文本来表达给定的意图、思想等

--- 自然语言生成 (Natural Language Generation, NLG)



什么是自然语言处理？

- 语言是**思维的载体**，是人类交流思想、表达情感最自然、最方便的工具
 - 人类历史上大部分知识是以语言文字形式记载和流传的
- 自然语言指的是人类语言，特指**文本符号**，而非语音信号
- 自然语言处理（Natural Language Processing, NLP）
 - 用计算机来**理解**和**生成**自然语言的各种理论和方法






自然语言处理属于认知智能任务

□ 语言是人类与其他动物最重要的区别

- 逻辑思维以语言的形式表达
- 知识以文字的形式记录和传播
- 需要更强的抽象和推理能力





自然语言处理的代表性应用



机器翻译



"Hey Alexa"



"Hey Siri"

智能助手




文本校对



舆情分析



智能教育



知识图谱



自然语言处理的研究历史悠久

自然语言处理的研究历史可以追溯到1947 年


- 1947年 Warren Weaver 提出了利用计算机翻译人类语言的可能
- 1949年发布《Translation》（翻译）备忘录
- 1950年 Alan Turing 发表《Computing Machinery and Intelligence》
- 1954年 Georgetown University与IBM 合作的机器翻译演示系统将60多个俄语句子翻译成了英文





自然语言处理的研究历史悠久

20世纪50年代末到60年代的初创期、20世纪70年代到80年代的理性主义时代、20世纪90年代到21世纪初的经验主义时代以及2006年至今的深度学习时代。





20世纪50年代末到60年代的初创期

符号学派和随机学派

- **Noam Chomsky**为代表的符号学派提出了形式语言理论，基于1957年发表的《Syntactic Structures》（句法结构）介绍了生成语法的概念，并提出了一种特定的生成语法称为转换语法。开启了使用数学方法研究语言的先河。
- 随机学派则是以1959年**Bledsoe**和**Browning**将贝叶斯方法（Bayesian method）应用于字符识别问题为代表。试图通过贝叶斯方法来解决自然语言处理中的问题。

计算语言学（Computational Linguistics）概念也被正式，1962年ACL成立，1965年第一届国际计算语言学大会（The International Conference on Computational Linguistics, COLING）



20世纪70年代到80年代的理性主义时代

基于逻辑的范式、基于规则的范式和随机范式

- 1970年Colmerauer等人使用逻辑方法研制Q系统语言的先河
- 1972年SHRDLU系统使用规则范式模拟了一个玩具积木世界
- 80年代初隐马尔可夫模型等模型应用于词性标注、姓名检索等



20世纪90年代到21世纪初的经验主义时代

基于机器学习和数据驱动

- 1989年机器翻译任务中引入语料库方法
- 朴素贝叶斯、K 近邻、支撑向量机、最大熵模型、神经网络、条件随机场、感知机等方法



2006年至今的深度学习时代

深度神经网络+向量表示

- 2006年基于深度信念网络 (Deep Belief Networks, DBN) 方法
- 2011年《Natural language processing (almost) from scratch》
- 2014 年 Seq2Seq (序列到序列) 的模型在机器翻译任务上取得了非常好的效果, 并且完全不依赖任何人工特征
- 循环神经网络、长短时记忆网络、递归神经网络、卷积神经网络、图神经网络等



2018年至今大模型

超大规模语言模型

- 2018年上下文相关的文本表示方法ELMo
- BERT、GPT、XLNet、ERNIE等预训练微调范式
- GPT3、Palm等超大规模语言模型





自然语言处理的主要研究内容


自然语言处理的研究内容十分庞杂

- **整体**：基础算法研究和应用技术研究
- **语言单位角度**：字、词、短语、句子、段落以及篇章等不同粒度
- **语言学研究角度**：形态学、语法学、语义学、语用学等不同层面
- **机器学习方法层面**：有监督、无监督、半监督、强化学习等

自然语言处理研究与机器学习和语言学研究交织在一起，使得自然语言处理的研究内容涉及范围广，学科交叉度大。



自然语言处理的主要研究内容





自然语言处理的主要研究内容

自然语言处理难的**根本原因**：自然语言在各个层面都广泛存在的各种各样的**歧义性**

- 自然语言文本从形式上是由字符（包括中文汉字、英文字母、符号）组成的字符串
- 由字母或者汉字可以组成词，由词可以组成词组，由词组可以组成句子，进而组成段落、篇章
- 无论哪种粒度的语言单元，还是从一个层级向上一个层级转变中都存在歧义和多义现象

形式上一样的字符串，可以理解为不同的词串、词组串，并有不同的意义

Joseph F. Kess 和 Ronald A. Hoppe 甚至还提出了“**语言无处不歧义**”理论





自然语言处理的主要难点—语音歧义

语音歧义 (Phonetic Ambiguity) 主要体现在口语中，是由于语言中同音异义词 (Homophone)、爆破音不完全、重音位置不明确等原因造成的。

- 汉语中只有413 个不同的音（节），如果结合声调的变化组合，也仅有1277 个音（节），但是汉字则多达数万个
- 英语中连读、爆破音、重音位置等造成的语音异义也非常常见

例如： 请问您贵姓？ 免贵姓 zhang
chéng shì：城市、程式、成事、城事
Please hand me the flower. 请把花递给我。
Please hand me the flour. 请把面粉递给我。



自然语言处理的主要难点—词语切分歧义

词语切分歧义 (Word Segmentation Ambiguity) 是由字符组成词语时的歧义现象。

- 英语等印欧语系的语言来说，绝大部分单词之间都由空格或标点分割
- 汉语、日语等语言来说，单词之间通常没有分隔符。

例如：
语言学是一门基础学科。
这门语言学起来很困难。
南京市长江大桥





自然语言处理的主要难点—词义歧义

词义歧义 (Word Sense Ambiguity) 是指词语具有相同形式但是不同意义。

例如：“打”字在《现代汉语词典（第七版）》中，有两个读音“dá”和“dǎ”，分别作为量词、动词和介词，在作为动词时“打”字有 24 个意项

打 dǎ 动词：

- (1) 用手或器具撞击物体：~ 门 | ~ 鼓
- (2) 器皿、蛋类等因撞击而破碎：碗 ~ 了 | 鸡飞蛋 ~
- (3) 殴打；攻打：~ 架 | ~ 援
- (4) 发生与人交涉的行为：~ 官司 | ~ 交道
- (5) 汲取；盛取：~ 米 | ~ 酱油



自然语言处理的主要难点—结构歧义

结构歧义 (Structural Ambiguity) 是由词组成词组或者句子时，由于其组成的词或词组间可能存在不同的语法或语义关系而出现的（潜在）歧义现象。

- “VP+ 的 + 是 +NP” 型歧义结构没有分隔符

例如：反对 | 的 | 是 | 少数人

- “VP+N1+ 的 +N2” 型歧义结构

例如：咬死了 | 猎人 | 的 | 狗

- “N1+ 和 +N2+ 的 +N3” 型歧义结构

例如：桌子 | 和 | 椅子 | 的 | 腿



自然语言处理的主要难点—指代和省略歧义

指代歧义 (Demonstrative Ambiguity) 是指代词 (如我, 你, 他等) 和代词词组 (如 “那件事”, “这一点” 等) 所指的事件可能存在歧义

例如: 猴子吃了香蕉, 因为它 饿了。
猴子吃了香蕉, 因为它 熟透了。

省略歧义 (Ellipsis Ambiguity) 是指自然语言中由于省略所产生的歧义

例如: 县政府同意乡政府报告。



自然语言处理的主要难点—语用歧义

语用歧义 (Pragmatic Ambiguity) 是指由于上下文、说话人属性、场景等语用方面的原因造成的歧义。一句话在不同的场合、由不同的人说、不同的语境，都可能产生不同的理解

例如：女子致电男友：地铁站见。如果你到了我还没到，你就等着吧。如果我到了你还没到，你就等着吧！！

自然语言并不是一成不变的，而是在动态发展中，存在大量未知语言现象。新词汇、新含义、新用法、新句型等层出不穷

例如：新词汇：双碳、双减、绝绝子、社恐、元宇宙

新含义：躺平、打工人、凡尔赛、青蛙、潜水、盖楼

新用法：走召弓虽、YYDS、回忆杀、求扩列、orz



自然语言处理的难点与特点

领导：“你这是什么**意思**？”

阿呆：“没什么**意思**，**意思意思**。”

领导：“你这就不够**意思**了。”

阿呆：“小**意思**，小**意思**。”

领导：“你这人真有**意思**。”

阿呆：“其实也没有别的**意思**。”

领导：“那我就只好**意思**了。”

阿呆：“是我不好**意思**。”





“人工智能皇冠上的明珠”

□ 自然语言处理成为**制约人工智能取得更大突破和更广泛应用的瓶颈**



“深度学习的下一个
前沿课题是**自然语言
理解**”

Yann LeCun

图灵奖得主、Facebook AI 负责人



“如果给我10亿美
金，我会用这10亿
美金建造一个
NASA级别的**自然
语言处理**研究项目”

Michael I. Jordan

美国双院院士、世界知名机器学习专家



“深度学习的下一个
大的进展应该是**让神
经网络真正理解文档
的内容**”

Geoffrey Hinton



图灵奖得主、深度学习之



“下一个十年，**懂语
言者得天下**”

沈向洋

美国工程院院士、微软前全球执行副总裁



图灵测试



自然语言处理任务层级

应用系统 (NLP+)

- 教育, 医疗, 司法, 金融, 机器人等

应用任务

- 信息抽取, 情感分析, 机器翻译, 对话系统等

基础任务

- 分词, 词性标注, 句法分析, 语义分析等


资源建设

- 语言学知识库建设, 语料库资源建设等






归结为四个基本问题





自然语言处理研究对象与层次



名: 语言符号
实: 客观事实、主观意见
知: 知识
境: 语言所处环境

形式: 名
语义: 名+实
推理: 名+实+知
语用: 名+实+知+境



“层次 x 任务” 二维表

	分类	解析	匹配	生成
形式	文本分类	词性标注 句法分析	搜索	机械式文摘
语义	情感分析	命名实体识别 语义角色标注	问答	机器翻译
推理	隐式情感分析		文本蕴含	写故事结尾
语境	反语			聊天





大纲

■ 基本概念

■ 基本范式

- 基于规则的方法、
- 基于机器学习的方法
- 基于深度学习的方法
- 基于大模型的方法



自然语言处理的基本范式

- 自然语言处理的发展经历了从理性主义到经验主义，再到深度学习三大历史阶段
- 基于规则的方法、基于机器学习的方法、基于深度学习的方法以及基于大模型的方法四种范式
- 四种范式基本对应了自然语言处理的不同发展阶段的重点

需要特别说明的是：

- 虽然以上四种范式来源于自然语言处理的不同发展阶段，有明显的发展先后顺序
- 在大部分自然语言处理任务的标准评测集合中基于深度学习的方法都好于基于机器学习的方法，更优于基于规则的方法很多
- 但是，这四种范式各有利弊，在实际应用中需要根据任务的特点、计算量、可控制性以及可解释性等具体情况进行选择




自然语言处理的基本范式

- 在机器学习和深度学习范式下，甚至对模型预测目标进行微小修正，通常都需要对模型进行重新训练
- 对模型预测目标进行微小修正，通常都需要对模型进行重新训练。对于未知任务的零样本学习（Zero-shot Learning）能力很少在上述范式中进行讨论和研究。
- 随着ChatGPT的发布，大模型所展现出来的文本生成能力以及对未知任务的泛化能力使得未来的自然语言处理的研究范式很可能会发生非常大的变化。




自然语言处理技术范式变迁

- 语义在计算机内部是如何**表示**的？
- 根据表示方法的不同，自然语言处理技术经历了**四次范式变迁**





基于符号（字符串）表示的专家知识



□ “土豆非常好吃。”的情感倾向性？

- 如果：出现褒义词 “好” “喜欢” 等
- 那么：结果为褒义
- 如果：出现 “不”
- 那么：结果倾向性取反

□ 优点

- 符合人类的直觉
- 可解释、可干预性好


□ 缺点

- 知识完备性不足
- 需要专家构建和维护
- 不便于计算



基于规则的方法

通过词汇、形式文法等制定的规则引入语言学知识，从而完成相应的自然语言处理任务





基于规则的方法

对于机器翻译任务可以构造如下规则库：

- IF 源语言主语 = 我 THEN 英语译文主语 = I
- IF 英语译文主语 = I THEN 英语译文 be 动词为 am/was
- IF 源语言 = 苹果 AND 没有修饰量词 THEN 英语译文 = apples


基于规则的方法从某种程度上可以说是在试图模拟人类完成某个任务时的思维过程

优点：直观、可解释、不依赖大规模数据。利用规则所表达出来的语言知识具有一定的可读性，不同的人之间可以相互理解。

缺点：覆盖率差、大规模规则构建代价大、难度高等



基于向量表示的统计模型



□ 使用高维、离散、稀疏的向量表示词

— 维度为词表大小，其中只有一位为1，其余为0

• **土豆**: [0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, ...]

• **马铃薯**: [0, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, ...]

□ 缺点


— 严重的数据稀疏问题

— 无法处理“多词一义”的现象



基于机器学习的方法

将自然语言处理任务转化为某种分类任务





基于机器学习的方法

分为四个步骤：数据构建、数据预处理、特征构建以及模型学习：

- (1) 数据构建阶段主要工作是针对任务的要求构建训练语料，也称为语料库 (Corpus)
- (2) 数据预处理阶段主要工作是利用自然语言处理基础算法对原始输入，从词汇、句法、结构、语义等层面进行处理，为特征构建提供基础。
- (3) 特征构建阶段主要工作是针对不同任务从原始输入、词性标注、句法分析、语义分析等结果和数据中提取对于机器学习模型有用的特征。
- (4) 模型学习阶段主要工作是根据任务，选择合适的机器学习模型，确定学习准则，采用相应的优化算法，利用语料库训练模型参数。




基于机器学习的方法

- 以人工特征构建为核心，针对所需的信息利用自然语言处理基础算法对原始数据进行预处理，并需要选择合适的机器学习模型，确定学习准则，以及采用相应的优化算法
- 整个流程中需要人工参与和选择的环节非常多，从特征设计到模型，再到优化方法以及超参数，并且这些选择非常依赖经验，缺乏有效的理论支持
- 对于复杂的自然语言处理任务需要在数据预处理阶段引入很多不同的模块，这些模块之间需要单独优化，其目标并不一定与任务总体目标一致，多模块的级联会造成错误传播




基于嵌入表示的深度学习模型




词嵌入 (Word Embedding)

- 直接使用一个**低维、连续、稠密**的向量表示词 (Bengio等2003)



词嵌入表示的赋值方法


- 通过优化在**下游任务**上的表现自动学习





基于深度学习的方法

将特征学习和预测模型融合，通过优化算法使得模型自动地学习出好的特征表示，并基于此进行结果预测






基于深度学习的方法

- 基于深度学习方法的流程简化很多，通常仅包含数据构建、数据预处理和模型学习三个部分
- 在数据预处理方面也大幅度简化，仅包含非常少量的模块
- 通过多层的特征转换，将原始数据转换为更抽象的表示。这些学习到的表示可以在一定程度上完全代替人工设计的特征，这个过程也叫做表示学习 (Representation Learning)
- 首先利用自监督任务对模型进行预训练，通过海量的语料学习到更为通用的语言表示，然后根据下游任务对预训练网络进行调整。这种预训练范式在几乎所有自然语言处理任务上都表现非常出色



预训练模型获得更好的表示




预训练 + 精调 = 自然语言处理新范式





基于大模型的方法

将大量各类型自然语言处理任务，统一为生成式自然语言理解框架





基于大模型的方法

- ChatGPT 所展现出来的通用任务理解能力和未知任务泛化能力，使得未来自然语言处理的研究范式可能进一步发生变化
- 在大规模语言模型构建阶段，通过大量的文本内容，训练模型长文本的建模能力，使得模型具有语言生成能力，并使得模型获得隐式的世界知识
- 在通用能力注入阶段，利用包括阅读理解、情感分析、信息抽取等现有任务的标注数据，结合人工设计的指令词对模型进行多任务训练，从而使得模型具有很好的任务泛化能力
- 特定任务使用阶段则变得非常简单，由于模型具备了通用任务能力，只需要根据任务需求设计任务指令，将任务中所需处理的文本内容与指令结合，然后就可以利用大模型得到所需结果



小结

自然语言处理（Natural Language Processing, NLP）是计算机科学领域和人工智能领域的重要研究方向之一，**旨在探索实现人与计算机之间用自然语言进行有效交流的理论与方法**。它融合了语言学、计算机科学、机器学习、数学、认知心理学等多学科内容，涉及从字、词、短语到句子、段落、篇章的多种语言单位，以及处理、理解、生成等不同层面的知识点，研究内容涉及的知识点多且复杂。自 20 世纪 90 年代以来，自然语言处理发展迅猛，各类任务和算法和研究范式层出不穷，在搜索引擎、医疗、金融、教育、司法等众多领域展示出重要作用。