

自然语言处理 (2025 春季学期)

五、预训练语言模型



大纲

- 概述
- 自回归预训练模型代表：GPT
- 自编码预训练模型代表：BERT
- 预训练语言模型的应用
- 深入理解BERT



动态词向量模型的问题

□ 数据

- 训练数据相对比较局限，例如CoVe要求使用双语平行句对

□ 模型

- 表示模型的参数量相对较小（相比预训练语言模型），模型深度不够

□ 用法

- 通常使用这类模型时，表示模型本身是不参与训练的（权重无更新）
- 表示模型本身不参与训练，一定程度上限制了表示模型在下游任务上的泛化能力




预训练模型三要素

大数据
(无标注文本)



大模型
(深度神经网络)



大算力
(并行计算集群)



GPT



GPT-2

GPT-3


以及更多
钱




南京大学
NANJING UNIVERSITY



常见计算设备



图形运算单元 (GPU)



张量运算单元 (TPU)



大纲

- 概述
- 自回归预训练模型代表：GPT
- 自编码预训练模型代表：BERT
- 预训练语言模型的应用
- 深入理解BERT





□ GPT: Generative Pre-Training

- OpenAI提出了“生成式预训练+判别式微调”框架
- 正式开启了自然语言处理领域“**预训练+微调**”的新时代

生成式预训练

- 在大规模文本数据上训练一个高容量的语言模型，从而学习更加丰富的上下文信息

判别式任务微调

- 将预训练好的模型适配到下游任务中，并使用有标注数据学习判别式任务






预训练-微调 范式

- 受到计算机视觉领域采用ImageNet对模型进行一次预选训练，使得模型可以通过海量图像充分学习如何提取特征，然后再根据任务目标进行模型精调的范式影响，自然语言处理领域基于预训练语言模型的方法也逐渐成为主流。
- ELMo为代表的动态词向量模型开启了语言模型预训练的大门，此后以GPT和BERT为代表的基于Transformer的大规模预训练语言模型的出现，使得自然语言处理全面进入了**预训练微调范式**新时代。
- 将预训练模型应用于下游任务时，**不需要了解太多的任务细节，不需要设计特定的神经网络结构**，只需要“微调”预训练模型，即使用具体任务的标注数据在预训练语言模型上进行监督训练，就可以取得显著的性能提升。



GPT: 模型结构

- OpenAI公司在2018年提出的GPT（Generative Pre-Training）模型是典型的生成式预训练语言模型之一。GPT-2模型结构如图6.4所示，由多层Transformer组成的单向语言模型，主要可以分为输入层，编码层和输出层三部分。






GPT: 模型结构

- GPT采用生成式预训练方法，单向意味着模型只能从左到右或从右到左对文本序列建模，所采用的Transformer结构保证了输入文本每个位置只能依赖过去时刻的信息。

- 给定文本序列 $w = w_1 w_2 \dots w_n$ ，GPT-2首先在输入层中将其映射为稠密的向量

$$v_i = v_i^t + v_i^p$$

- v_i^t 是词 w_i 的词向量， v_i^p 是词 w_i 的位置向量， v_i 为第 i 个位置的单词经过模型输入层（第0层）后的输出
- 经过输入层编码，模型得到表示向量序列 $V = v_1 \dots v_n$ ，随后将 V 送入模型编码层





GPT: 模型结构

- 编码层由L个Transformer模块组成，在自注意力机制的作用下，每一层的每个表示向量都会包含之前位置表示向量的信息，使每个表示向量都具备丰富的上下文信息，并且经过多层解码后，GPT-2能得到每个单词层次化的组合式表示，其计算过程表示如下：


$$h^{(L)} = \text{Transformer-Block}^{(L)}(h_i^{(0)})$$

- GPT-2模型的输出层基于最后一层的表示 $h^{(L)}$ ，预测每个位置上的条件概率，其计算过程可以表示为：

$$P(w_i|w_1, \dots, w_{i-1}) = \text{Softmax}(\mathbf{W}^e h_i^{(L)} + \mathbf{b}^{out})$$

- 单向语言模型是按照阅读顺序输入文本序列 w ，用常规语言模型目标优化 w 的最大似然估计，使之能根据输入历史序列对当前词能做出准确的预测：

$$\mathcal{L}^{\text{PT}}(w) = - \sum_{i=1}^n \log P(w_i|w_0 \dots w_{i-1}; \theta)$$





GPT: 无监督预训练

□ 从左至右对输入文本进行建模

— 给定文本序列计算最大似然估计

$$\mathcal{L}^{\text{PT}}(x) = \sum_i \log P(x_i | x_{i-k} \cdots x_{i-1}; \theta)$$

— GPT使用了多层Transformer作为模型的基本结构

$$\mathbf{h}^{[0]} = \mathbf{e}_x \mathbf{W}^e + \mathbf{W}^p$$

$$\mathbf{h}^{[l]} = \text{Transformer-Block}(\mathbf{h}^{[l-1]}), \quad \forall l \in \{1, 2, \cdots, L\}$$

$$P(x) = \text{Softmax}(\mathbf{h}^{[L]} \mathbf{W}^e \top)$$



GPT：有监督任务微调

□ 利用下游任务的有标注数据，对GPT模型进行微调

— 利用GPT最后一层的表示来完成相关预测任务

$$P(y|x_1 \cdots x_n) = \text{Softmax}(\mathbf{h}^{[L]} \mathbf{W}^y)$$

$$\mathcal{L}^{\text{FT}}(\mathcal{C}) = \sum_{(x,y)} \log P(y|x_1 \cdots x_n)$$


— 为缓解灾难性遗忘（**Catastrophic Forgetting**）问题，通常会采用混合预训练任务损失和下游精调损失

$$\mathcal{L}(\mathcal{C}) = \mathcal{L}^{\text{FT}}(\mathcal{C}) + \lambda \mathcal{L}^{\text{PT}}(\mathcal{C})$$



GPT: 适配不同的下游任务

□ 根据任务特点，设置不同的输入输出形式





大纲

- 概述
- 自回归预训练模型代表：GPT
- 自编码预训练模型代表：BERT
- 预训练语言模型的应用
- 深入理解BERT





□ BERT: Bidirectional Encoder Representations from Transformers (NAACL 2019 Best Paper)

- 提出了一种双向预训练语言模型方法
- 利用大规模自由文本训练两个无监督预训练任务
- BERT在众多NLP任务中获得了显著性能提升
- 进一步强调了使用通用预训练取代繁杂的任务特定的模型设计




BERT利用掩码机制构造了基于上下文预测中间词的预训练任务，相较于传统的语言模型建模方法，BERT能进一步挖掘上下文所带来的丰富语义。





□ GPT/BERT/ELMo之间的对比

- GPT: 单向从左至右的Transformer语言模型
- ELMo: 将独立的前向和后向的LSTM语言模型拼接所得
- BERT: 双向 Transformer语言模型






BERT: 模型结构

□ 整体结构

- 由深层Transformer模型构成
 - base: 12层, 参数量110M
 - large: 24层, 参数量330M

□ 预训练任务

- 掩码语言模型 (Masked Language Model, MLM)
- 下一个句子预测 (Next Sentence Prediction, NSP)





BERT：输入表示

□ BERT的输入表示由三部分组成

- 词向量：通过词向量矩阵将输入文本转换为实值向量表示
- 块向量：编码当前词属于哪一个块
- 位置向量：编码当前词的绝对位置

BERT输入层采用了**WordPiece分词**，根据词频，决定是否将一个完整的词切分为多个子词以缓解OOV问题

例如：单词highest可以被切分为high和##est两个子词。



BERT: 输入表示

□ BERT的输入表示由三部分组成

- 词向量：通过词向量矩阵将输入文本转换为实值向量表示
- 块向量：编码当前词属于哪一个块，块编码从0开始计数。
- 位置向量：编码当前词的绝对位置

原始输入	[CLS]	天	气	晴	朗	[SEP]	我	喜	欢	[SEP]
词向量	$v_{[CLS]}$	$v_{\text{天}}$	$v_{\text{气}}$	$v_{\text{晴}}$	$v_{\text{朗}}$	$v_{[SEP]}$	$v_{\text{我}}$	$v_{\text{喜}}$	$v_{\text{欢}}$	$v_{[SEP]}$
	+	+	+	+	+	+	+	+	+	+
块向量	v_A	v_A	v_A	v_A	v_A	v_A	v_B	v_B	v_B	v_B
	+	+	+	+	+	+	+	+	+	+
位置向量	v_0	v_1	v_2	v_3	v_4	v_5	v_6	v_7	v_8	v_9






BERT: 模型参数

- BERT的编码层采用多层Transformer结构，使用L表示所采用的层数，H表示每层的隐藏单元数，A是指自注意力头数量。在文献给出了两种不同的参数设置，**BERT_{BASE}**使用L=12，H=768，A=12，总参数数量为**110M**，**BERT_{LARGE}**使用L=24，H=1024，A=16，总参数数量为**340M**。

We primarily report results on two model sizes: **BERT_{BASE}** (L=12, H=768, A=12, Total Parameters=110M) and **BERT_{LARGE}** (L=24, H=1024, A=16, Total Parameters=340M).

BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding





BERT: 模型参数


□ BERT

表示


不同

110M

输入层



Transformer block



的层数, H

合出了两种

参数量为

110M。

综上, BERT-base的参数总量: $23837184 + 85054464 = 108891648 \approx 109M$




DyT (Dynamic Tanh)

Transformers without Normalization

Jiachen Zhu^{1,2}, Xinlei Chen¹, Kaiming He³, Yann LeCun^{1,2}, Zhuang Liu^{1,4,†}



¹FAIR, Meta, ²New York University, ³MIT, ⁴Princeton University

[†]Project lead



$$\text{normalization}(x) = \gamma * \left(\frac{x - \mu}{\sqrt{\sigma^2 + \epsilon}} \right) + \beta$$

$$\text{DyT}(x) = \gamma * \tanh(\alpha x) + \beta$$





DyT (Dynamic Tanh)

Algorithm 1 Pseudocode of DyT layer.

```
# input x has the shape of [B, T, C]
# B: batch size, T: tokens, C: dimension

class DyT(Module):
    def __init__(self, C, init_α):
        super().__init__()
        self.α = Parameter(ones(1) * init_α)
        self.γ = Parameter(ones(C))
        self.β = Parameter(zeros(C))

    def forward(self, x):
        x = tanh(self.alpha * x)
        return self.γ * x + self.β
```


On scaling parameters. We always simply initialize γ to an all-one vector and β to an all-zero vector following normalization layers. For the scaler parameter α , a default initialization of 0.5 is generally sufficient, except for LLM training. A detailed analysis of α initialization is provided in Section 7. Unless explicitly stated otherwise, α is initialized to 0.5 in our subsequent experiments.





BERT: 双向注意力 vs 因果注意力

- 需要注意的是，与GPT中Transformer结构所采用的约束自注意力（Constrained Self-Attention）仅关注当前单元左侧上下文不同，BERT采用的Transformer结构使用了双向多头自注意机制，不仅关注当前单元左侧上下文情况，也会关注右侧上下文。





BERT：基本预训练任务

□ 预训练任务1：Masked Language Model (MLM)

- 将输入序列中的部分token进行掩码，并且要求模型将它们进行还原
- 在BERT中，会将15%的输入文本进行mask
 - 以 80% 的概率替换为 [MASK] 标记；
 - 以 10% 的概率替换为词表中的任意一个随机词；
 - 以 10% 的概率保持原词不变，即不替换。

原文本

The man went to the store to buy some milk.

80% 概率替换为 [MASK]

The man went to the [MASK] to buy some milk.

10% 概率替换为随机词

The man went to the apple to buy some milk.

10% 概率保持原样

The man went to the store to buy some milk.



BERT: 基本预训练任务

□ 预训练任务1: Masked Language Model (MLM)

– 输入层

$$X = [\text{CLS}] x'_1 x'_2 \cdots x'_n [\text{SEP}]$$


$$\mathbf{v} = \text{InputRepresentation}(X)$$

– BERT编码层

$$\mathbf{h} = \text{Transformer}(\mathbf{v})$$

– 输出层

$$P_i = \text{Softmax}(\mathbf{h}_i^m \mathbf{W}^t{}^\top + \mathbf{b}^o)$$





BERT：基本预训练任务

□ 预训练任务2： Next Sentence Prediction (NSP)

- 学习两段文本之间的关系（上下文信息）
- 预测Sentence B是否是Sentence A的下一个句子
 - 正样本：文本中相邻的两个句子“句子 A”和“句子 B”，构成“下一个句子”关系
 - 负样本：将“句子 B”替换为语料库中任意一个句子，构成“非下一个句子”关系（ 50%概率替换，将训练样本的正负例比例控制在1:1 ）

	正样本	负样本
第一段文本	The man went to the store.	The man went to the store.
第二段文本	He bought a gallon of milk.	Penguins are flightless.



BERT: 基本预训练任务

□ 预训练任务2: Next Sentence Prediction (NSP)

– 输入层

$$X = [\text{CLS}] x_1^{(1)} x_2^{(1)} \cdots x_n^{(1)} [\text{SEP}] x_1^{(2)} x_2^{(2)} \cdots x_m^{(2)} [\text{SEP}]$$


$$\mathbf{v} = \text{InputRepresentation}(X)$$

– BERT编码层

$$\mathbf{h} = \text{Transformer}(\mathbf{v})$$

– 输出层

$$P = \text{Softmax}(\mathbf{h}_0 \mathbf{W}^P + \mathbf{b}^0)$$





BERT: 更多预训练任务

□ 整词掩码（Whole Word Masking）

- MLM: 随机选取一定比例的WordPiece子词
- WWM: 随机选取一定比例的**整词**，属于同一个整词的WordPiece子词均被掩码
- 总掩码数量不变，变动的是掩码位置的选取

原始句子	the man jumped up , put his basket on phil ##am ##mon ' s head
原始掩码输入	[M] man [M] up , put his [M] on phil [M] ##mon ' s head
整词掩码输入	the man [M] up , put his basket on [M] [M] [M] ' s head

原始句子	使用语言模型来预测下一个词的概率。
中文分词	使用语言模型来预测下一个词的概率。
原始掩码输入	使[M]语言[M]型来[M]测下一[M]词的概率。
整词掩码输入	使用语言[M][M]来[M][M]下一个词的概率。





BERT: 更多预训练任务

□ N-gram掩码 (N-gram Masking)

- 对一个连续的N-gram单元进行掩码, 进一步增加MLM任务的难度
- 难度: N-gram Masking > Whole Word Masking > MLM

We went to the store to buy some fruits.

→ We went to [M] store to [M] some [M].

Original
MLM

→ We went to [M] [M] [M] buy some fruits.

N-gram
Masking





BERT: 更多预训练任务

□ 三种掩码策略的联系与区别

	MLM	WWM	NM
最小掩码单位 (英文)	WordPiece 子词	WordPiece 子词	WordPiece 子词
最小掩码单位 (中文)	字	字	字
最大掩码单位 (英文)	WordPiece 子词	词	多个子词
最大掩码单位 (中文)	字	词	多个字



大纲

- 概述
- 自回归预训练模型代表：GPT
- 自编码预训练模型代表：BERT
- 预训练语言模型的应用
- 深入理解BERT





预训练语言模型应用

□ 特征提取和模型微调


— 特征提取

- 仅利用BERT提取输入文本特征，生成对应的上下文语义表示
- BERT本身不参与目标任务的训练，即BERT部分只进行解码（无梯度回传）

— 模型微调

- 利用BERT作为下游任务模型基底，生成文本对应的上下文语义表示
- 参与下游任务的训练，即在下游任务学习过程中，BERT对自身参数进行更新

— 通常使用“模型微调”的方法，因其效果更佳






预训练语言模型应用

□ 单句文本分类（Single Sentence Classification）

- 最常见的自然语言处理任务，需要将输入文本分成不同类别
- 例如：将影评文本输入到分类模型中，将其分成“褒义”和“贬义”类别





预训练语言模型应用

□ 单句文本分类（Single Sentence Classification）

— 输入层

$$X = [\text{CLS}] x_1 x_2 \cdots x_n [\text{SEP}]$$

$$v = \text{InputRepresentation}(X)$$

— BERT编码层

$$h = \text{BERT}(v)$$

— 分类输出层


$$P = \text{Softmax}(h_0 W^0 + b^0)$$



预训练语言模型应用

□ 句对文本分类（Sentence Pair Classification）

- 与单句文本分类任务类似，需要将一对文本分成不同类别
- 例如：文本蕴含任务中，将句对分成“蕴含”或者“冲突”类别





预训练语言模型应用

□ 句对文本分类（Sentence Pair Classification）

— 输入层

$$X = [\text{CLS}] x_1^{(1)} x_2^{(1)} \cdots x_n^{(1)} [\text{SEP}] x_1^{(2)} x_2^{(2)} \cdots x_m^{(2)} [\text{SEP}]$$

$$v = \text{InputRepresentation}(X)$$

— BERT编码层

$$h = \text{BERT}(v)$$

— 分类输出层

$$P = \text{Softmax}(h_0 W^0 + b^0)$$





预训练语言模型应用

□ 阅读理解（Reading Comprehension）

- 以抽取式阅读理解为例进行说明，要求机器在阅读篇章和问题后给出相应 的答案，而答案要求是从篇章中抽取出的一个文本片段（Span）

【篇章】


南京大学的历史可以追溯到 1902 年创建的三江师范学堂。1952 年，在全国高校院系调整中，南京大学调整出工学、农学、师范等部分院系后与创办于 1888 年的金陵大学文、理学院等合并，校址从四牌楼迁至鼓楼金大原址。1994 年，南京大学被确定为国家“211 工程”重点支持的大学；1999 年，进入国家“985 工程”首批重点建设的高水平大学行列。

【问题】

南京大学哪一年入选国家首批“985 工程”？

【答案】

1999 年





预训练语言模型应用

□ 阅读理解（Reading Comprehension）

— 输入层

$$X = [\text{CLS}] q_1 q_2 \cdots q_n [\text{SEP}] p_1 p_2 \cdots p_m [\text{SEP}]$$

$$v = \text{InputRepresentation}(X)$$

— BERT编码层

$$h = \text{BERT}(v)$$

— 答案输出层

$$P^s = \text{Softmax}(hW^s + b^s)$$

$$P^e = \text{Softmax}(hW^e + b^e)$$




预训练语言模型应用

□ 序列标注（Sequence Tagging）

- 以命名实体识别任务（NER）为例，对给定输入文本的每个词输出一个标签，以此指定某个命名实体的边界信息

原始标签	B-PER	I-PER	O	O	O	O	B-LOC	
原始输入	John	Smith	has	never	been	to	Harbin	
处理后的标签	B-PER	I-PER	O	O	O	O	B-LOC	B-LOC
处理后的输入	John	Smith	has	never	been	to	Ha	##rbin





预训练语言模型应用

□ 序列标注 (Sequence Tagging)

— 输入层

$$X = [\text{CLS}] x_1 x_2 \cdots x_n [\text{SEP}]$$

$$\mathbf{v} = \text{InputRepresentation}(X)$$

— BERT编码层

$$\mathbf{h} = \text{BERT}(\mathbf{v})$$

— 答案输出层

$$P_t = \text{Softmax}(\mathbf{h}_t \mathbf{W}^o + \mathbf{b}^o), \quad \forall t \in \{1, \cdots, N\}$$





大纲

- 概述
- 自回归预训练模型代表：GPT
- 自编码预训练模型代表：BERT
- 预训练语言模型的应用
- 深入理解BERT





深入理解BERT

□ 可解释性

- 自解释：在模型构建之初针对性地设计其结构，使其具备可解释性
- 事后解释：对于 BERT 等大规模预训练模型的解释性研究，集中在此类

□ 两个角度

- 自注意力机制
- 表示学习

□ 两种方法


- 可视化（Visualization）
- 探针实验（Probing）



深入理解BERT

□ 自注意力可视化分析

- 自注意力的分析将有助于理解 BERT 模型对于关系（relational）特征的学习能力






深入理解BERT

□ 自注意力可视化分析

- 计算各层注意力分布的信息熵
- 浅层阶段熵值较大，中间阶段熵值减小，深层阶段熵值再次增大
- 一定程度上可以反映 BERT模型中信息聚合（或语义组合）的过程





深入理解BERT

□ 探针实验


- 设计特定的探针，对于待分析对象（如自注意力或隐含层表示）进行特定行为分析
- 探针通常是一个非参或者非常轻量 的参数模型（如线性分类器），它接受待分析对象作为输入，并对特定行为预测
- 预测的准确度可以作为待分析对象是否具有该行为的衡量指标



深入理解BERT

□ 探针实验

- 为了检验某个自注意力头对直接宾语（Direct object, dobj）关系的表达能力，可以设计一个探针对该自注意力头在dobj句法关系预测上的表现进行分析
- 在BERT第8层第10个自注意力头的注意力分布中，其中红色高亮部分即为dobj关系
- 结果表明在BERT模型中，确实存在一部分自注意力头较好地捕捉到特定的句法关系






深入理解BERT

□ 探针实验

- 自注意力反映了预训练模型内部信息的聚合过程，而模型的各层隐含层表示是聚合的结果
- 对预训练编码器的隐含层表示直接进行探针实验，更好地理解其特性
- 探针可以是一个简单的线性分类器，该分类器利用模型的隐含层表示作为特征在目标任务（如词性标注）上训练，从而根据该任务的表现对预训练模型隐含层表示中蕴含的语言学特征评估





小结

- 概述
- 自回归预训练模型代表：GPT
- 自编码预训练模型代表：BERT
- 预训练语言模型的应用
- 深入理解BERT

