

自然语言处理 (2025 春季学期)

十五、DEEPSEEK系列模型原理简介



DeepSeek-R1 的横空出世

Nature News报道: “中国的廉价且开源的大型语言模型震撼了科学界!”

由中国研发的DeepSeek-R1大模型是一种既具备**高性价比**又完全**开源**的“**推理**”模型, 其性能可与OpenAI的**o1模型媲美**。通过模仿人类推理过程, 这些模型能够逐步生成响应, 在解决科学问题时表现得比早期大模型更为出色, 可能对科研工作产生深远的影响...

NEWS | 23 January 2025

China's cheap, open AI model DeepSeek thrills scientists

DeepSeek-R1 performs reasoning tasks at the same level as OpenAI's o1 – and is open for researchers to examine.



南京大學
NANJING UNIVERSITY



从DeepSeek-V1到R1

Model	AIME 2024	CNMO 2024	LiveCodeBench	SWE Verified
DeepSeek V2	4.6	2.8	11.6	-
DeepSeek V2 Chat	16.7	10.8	28.7	22.6
DeepSeek V3	39.2	43.2	36.2	42.0
DeepSeek R1	79.8	78.8	65.9	49.2

V1

发布时间: 2024.1
核心技术: 类LLaMA架构+SFT+RLHF
训练数据量: 2T
训练稳定程度: 不稳定
最大参数量: 67B

V2

发布时间: 2024.5
核心技术: MoE (更多共享专家) + MLA (多头潜在注意力)
训练数据量: 8T
训练稳定程度: 较稳定
最大参数量: 236B (激活21B)
训练成本: 172.8K GPU小时

V3

发布时间: 2024.12
核心技术: 基于bias 负载均衡 + MTP (多词元预测)
训练数据量: 14T
训练稳定程度: 稳定
最大参数量: 671B (激活37B)
训练成本: 2788KGPU小时/\$5.58M

R1-Zero

发布时间: 2025.1
核心技术: 只使用RL学会推理能力 + 将RL引入基模型架构
训练稳定程度: 很稳定
最大参数量: 671B (激活37B)



R1

发布时间: 2025.1
核心技术: SFT学习推理格式 + RL学习推理能力
训练稳定程度: 很稳定
最大参数量: 671B (激活37B)

★ GRPO (DeepSeekMath, 2024.2)


- 无须价值网络
- 提高学习稳定性
- 降低学习开销





DeepSeek的核心贡献


- 只用RL习得推理能力：只使用强化学习（RL），模型自主学习到推理能力，性能接近o1模型
- 极致的模型架构优化：训练、推理速度更快，远超o1类模型，极大节约硬件成本
- 开源模型及蒸馏模型：DeepSeek坚持开源精神，开放了 R1模型及其蒸馏出的子模型





自然语言处理的发展历史

□ DeepSeek-R1 引发自然语言处理的 **第六次范式变迁**



推理 (Reasoning) 是指根据已知的信息、事实、规则或前提，通过一定的思维过程和方法，推导出新的结论、判断或知识的认知活动。它是人类思维和智能的核心组成部分，也是人工智能、科学研究和日常决策中的关键能力。



推理采用的核心技术

□ 思维链 (Chain-of-Thought, COT)

- 一系列中间推理步骤，相当于在求解问题过程中将解题步骤也写出来
- 早期的思维链能力是模型自发“涌现”的

(a) 少样例推理

样例

问：小明有5个乒乓球，他又买了2筒乒乓球，每筒有3个。
小明现在有多少乒乓球？

答：11个。

问：现在一共有16个球，其中的一半是小华的，小华的球中有一半是蓝色的。小华的球中有多少蓝色？

答：

(输出) 8个。

(c) 零样例推理

问：现在一共有16个球，其中的一半是小华的，小华的球中有一半是蓝色的。小华的球中有多少是蓝色的？

答：

(输出) 8个。

(b) 少样例思维链推理 (Wei et al., 2022)

问：小明有5个乒乓球，他又买了2筒乒乓球，每筒有3个。
小明现在有多少乒乓球？

答：小明一开始有5个乒乓球，在买了2筒后增加了2乘3等于6个，加起来一共11个。

问：现在一共有16个球，其中的一半是小华的，小华的球中有一半是蓝色的。小华的球中有多少蓝色？

答：

(输出) 16的一半是8个，8个的一半是4个。Ω

(d) 零样例思维链推理 (Kojima et al., 2022)

问：现在一共有16个球，其中的一半是小华的，小华的球中有一半是蓝色的。小华的球中有多少是蓝色的？

答：让我们一步一步地思考。

(输出) 16的一半是8个，8个的一半是4个。



只用RL习得推理能力 DeepSeek-R1-Zero






R1-Zero核心技术

全新的技术栈：基于结果的**极简版**强化学习（只将规则获得的准确率作为奖励）


- ◆ **强化学习框架：**使用 **GRPO (Group Relative Policy Optimization)** 作为强化学习框架
- ◆ **奖励模型：****结果/规则奖励**，奖励分为**准确率奖励 (accuracy rewards)** 和**格式奖励 (format rewards)**，确保模型输出正确的答案格式和推理过程





R1-Zero核心技术

GRPO (Group Relative Policy Optimization) : 利用当前策略模型进行多次采样, 并使用平均奖励值近似价值函数, 从而避免了对价值函数的显式训练, 这样做既减少了计算开销, 又避免了价值函数训练的困难, 提高了模型学习的稳定性【DeepSeekMath, 2024.2】





R1-Zero实验结果

性能提升: AIME 2024 的 pass@1 分数: **39.2% → 71.0%**, 接近 OpenAI-o1-preview

- ◆ RL 不需要fancy复杂的算法, **简单的GRPO就够用**
- ◆ RL需要**大量的数据**: R1-Zero训了8000个step, 如果每个step 采样的sample量为1024 , 那也到了8M级别
- ◆ RL训练不需要过程奖励, **结果奖励足够**

Model	AIME 2024		MATH-500	GPQA Diamond	LiveCode Bench	CodeForces
	pass@1	cons@64	pass@1	pass@1	pass@1	rating
OpenAI-o1-mini	63.6	80.0	90.0	60.0	53.8	1820
OpenAI-o1-0912	74.4	83.3	94.8	77.3	63.4	1843
DeepSeek-R1-Zero	71.0	86.7	95.9	73.3	50.0	1444

Table 2 | Comparison of DeepSeek-R1-Zero and OpenAI o1 models on reasoning-related benchmarks.

* <https://arxiv.org/abs/2501.12948>



R1-Zero实验结果

性能提升: AIME 2024 的 pass@1 分数: **39.2% → 71.0%**, 接近 OpenAI-o1-preview

◆ 为什么不需要过程奖励, **结果奖励足够了?**

- ◆ 过程奖励是很难找到一个好的定义且容易被hack
- ◆ 数学问题是固定格式, 且当前评判只检验最终结果, 而无关过程。优化的目标自然是得到高准确率, 而不在于文本输出的可读性和过程准确性

Model	AIME 2024		MATH-500	GPQA Diamond	LiveCode Bench	CodeForces
	pass@1	cons@64	pass@1	pass@1	pass@1	rating
OpenAI-o1-mini	63.6	80.0	90.0	60.0	53.8	1820
OpenAI-o1-0912	74.4	83.3	94.8	77.3	63.4	1843
DeepSeek-R1-Zero	71.0	86.7	95.9	73.3	50.0	1444

Table 2 | Comparison of DeepSeek-R1-Zero and OpenAI o1 models on reasoning-related benchmarks.

* <https://arxiv.org/abs/2501.12948>



R1-Zero实验结果

性能提升: AIME 2024 的 pass@1 分数: **39.2% → 71.0%**, 接近 OpenAI-o1-preview

强化学习的可扩展性: 随着强化学习步骤数增加, 模型的性能逐步增强




Figure 2 | AIME accuracy of DeepSeek-R1-Zero during training. For each question, we sample 16 responses and calculate the overall average accuracy to ensure a stable evaluation.

* <https://arxiv.org/abs/2412.18747>



R1-Zero实验结果

性能提升: AIME 2024 的 pass@1 分数: **39.2% → 71.0%**, 接近 OpenAI-o1-preview

强化学习的可扩展性: 随着强化学习步骤数增加, 模型的性能逐步增强

强化学习的Aha时刻: 随着强化学习步骤数增加, 会在某一步突然涌现出**反思/自我评估机制**

Question: If $a > 1$, then the sum of the real solutions of $\sqrt{a - \sqrt{a+x}} = x$ is equal to

Response: <think>

To solve the equation $\sqrt{a - \sqrt{a+x}} = x$, let's start by squaring both ...

$$(\sqrt{a - \sqrt{a+x}})^2 = x^2 \implies a - \sqrt{a+x} = x^2.$$

Rearrange to isolate the inner square root term:

$$(a - x^2)^2 = a + x \implies a^2 - 2ax^2 + (x^2)^2 = a + x \implies x^4 - 2ax^2 - x + (a^2 - a) = 0$$

...

Wait, wait. Wait. That's an aha moment I can flag here.

Let's reevaluate this step-by-step to identify if the correct sum can be ...

We started with the equation:

$$\sqrt{a - \sqrt{a+x}} = x$$

First, let's square both sides:

$$a - \sqrt{a+x} = x^2 \implies \sqrt{a+x} = a - x^2$$

Next, I could square both sides again, treating the equation: ...

...

Table 3 | An interesting "aha moment" of an intermediate version of DeepSeek-R1-Zero. The model learns to rethink using an anthropomorphic tone. This is also an aha moment for us, allowing us to witness the power and beauty of reinforcement learning.





R1-Zero实验结果

强化学习的长思维链自动拓展：

- ◆ 随着强化学习的步骤数增加，可以实现**思维链长度自然增长**




Figure 3 | The average response length of DeepSeek-R1-Zero on the training set during the RL process. DeepSeek-R1-Zero naturally learns to solve reasoning tasks with more thinking time.

* <https://arxiv.org/abs/2501.12548>



南京大学
NANJING UNIVERSITY



DeepSeek-R1


提升推理的规范性和泛化性



R1技术路线

冷启动 (Cold Start)：为了解决 DeepSeek-R1-Zero 的**可读性差**（如推理格式性差、语言混杂等）和**训练不稳定的问题**，DeepSeek-R1引入了少量冷启动数据进行预训练，这些数据包含长CoT样本。收集方法包括：

- ◆ 使用长 CoT 示例进行少样本提示
- ◆ 直接提示DeepSeek-R1-Zero 模型生成带反思和验证的详细答案
- ◆ 收集 DeepSeek-R1-Zero 的可读格式输出并**经人工标注者后处理**






R1技术路线

多阶段训练：包括两个强化学习阶段和两个监督微调阶段。

- ◆ **第一阶段**通过冷启动数据进行监督微调（SFT）
- ◆ **第二阶段**进行推理导向的强化学习（RL）
- ◆ **第三阶段**通过拒绝采样（rejection sampling）生成新的监督微调数据（SFT）
- ◆ **第四阶段**再次进行强化学习以优化模型在所有场景下的表现（RL）





R1技术路线

性能提升:

- ◆ AIME 2024 的 pass@1 分数:
71.0 → 79.8%, 接近 OpenAI-o1
- ◆ Long CoT Warmup 能带来更好的可读性。DeepSeek-R1-Zero的思考空间很混沌, 通过SFT初始化, 能够让思维空间更加像人类的思维增加稳定性

Benchmark (Metric)		Claude-3.5- Sonnet-1022	GPT-4o 0513	DeepSeek V3	OpenAI o1-mini	OpenAI o1-1217	DeepSeek R1
English	Architecture	-	-	MoE	-	-	MoE
	# Activated Params	-	-	37B	-	-	37B
	# Total Params	-	-	671B	-	-	671B
	MMLU (Pass@1)	88.3	87.2	88.5	85.2	91.8	90.8
	MMLU-Redux (EM)	88.9	88.0	89.1	86.7	-	92.9
	MMLU-Pro (EM)	78.0	72.6	75.9	80.3	-	84.0
	DROP (3-shot F1)	88.3	83.7	91.6	83.9	90.2	92.2
	IF-Eval (Prompt Strict)	86.5	84.3	86.1	84.8	-	83.3
	GPQA Diamond (Pass@1)	65.0	49.9	59.1	60.0	75.7	71.5
Code	SimpleQA (Correct)	28.4	38.2	24.9	7.0	47.0	30.1
	FRAMES (Acc.)	72.5	80.5	73.3	76.9	-	82.5
	AlpacaEval2.0 (LC-winrate)	52.0	51.1	70.0	57.8	-	87.6
	ArenaHard (GPT-4-1106)	85.2	80.4	85.5	92.0	-	92.3
	LiveCodeBench (Pass@1-COT)	38.9	32.9	36.2	53.8	63.4	65.9
Math	Codeforces (Percentile)	20.3	23.6	58.7	93.4	96.6	96.3
	Codeforces (Rating)	717	759	1134	1820	2061	2029
	SWE Verified (Resolved)	50.8	38.8	42.0	41.6	48.9	49.2
	Aider-Polyglot (Acc.)	45.3	16.0	49.6	32.9	61.7	53.3
	AIME 2024 (Pass@1)	16.0	9.3	39.2	63.6	79.2	79.8
Math	MATH-500 (Pass@1)	78.3	74.6	90.2	90.0	96.4	97.3
	CNMO 2024 (Pass@1)	13.1	10.8	43.2	67.6	-	78.8



极致的模型架构优化






主要模型架构优化技术

算法优化

- ◆ DeepSeekMoE (Mixture of Experts)
- ◆ 多头隐含注意力 (Multi-head Latent Attention, MLA)
- ◆ 多词元预测 (Multi-Token Prediction, MTP)

Infra优化

- ◆ FP8混合精度训练
- ◆ DualPipe
- ◆ 跨节点All-All通信






算法优化——DeepSeekMoE

MoE每生成一个词元激活不同的参数

- ◆ 增加模型容量
- ◆ 节约计算资源

DeepSeekMoE的特点

- ◆ 更多专家 (256个)
- ◆ 每次选择更专家 (8个)
- ◆ 共享专家 (1个)





算法优化——DeepSeekMoE

Feature	DeepSeek-V2	DeepSeek-V3	DeepSeek-R1
Dynamic Expert Activation	✗	✓ (Bias-based selection)	✓ (RL-based selection)
Device-Limited Routing (DLR)	✓	✓ (Node-Limited Routing)	✓ (Device-Constrained Expert Allocation)
Auxiliary Loss for Load Balancing	✓	✗ (Bias-based adjustments)	✗ (RL-based adaptive balancing)
RL-Based Routing	✗	✗	✓
Hierarchical Gating for Expert Selection	✗	✓	✓ (Entropy-aware adjustment)
Improved Expert Selection Mechanism	✗	✓ (Sigmoid-based)	✓ (RL-optimized selection)
Cross-Device Communication Reduction	✓ (Device-limited routing)	✓ (Node-limited routing)	✓ (35% lower latency with DCEA)
Token Dropping for Computational Efficiency	✓	✗ (No token dropping)	✗ (No token dropping)
Sparse Activation Strategy	✓ (Top-K gating)	✓ (Hierarchical Top-K gating)	✓ (Hierarchical Entropy-Gated MoE)
Training Stability	Moderate	High	Very High
Inference Speed Optimization	Moderate	High	Very High
Load Balancing Strategy	Loss-based balancing	Bias-based adaptive balancing	RL-based adaptive balancing




算法优化——多头隐含注意力（MLA）

KQV降维

- ◆ 将Key-Query-Value (KQV)矩阵映射到低维隐空间

减少KV-cache的存储空间

- ◆ 提高推理速度
- ◆ 支持更长上下文以及更大的batch





算法优化——多头隐含注意力（MLA）


Feature	DeepSeek-V2	DeepSeek-V3	DeepSeek-R1
Low-Rank KV Compression	✓	✓ (Optimized with Factorized Projections)	✓ (RL-Optimized Adaptive Compression)
Query Compression	✗	✓ (Static Low-Rank Query Compression)	✓ (RL-Guided Dynamic Query Compression)
KV Cache Reduction	✓ (93.3% Reduction)	✓ (40% Further Reduction)	✓ (25% Further Reduction over V3)
RoPE Application	✓ (Decoupled RoPE)	✓ (Decoupled with Context-Specific Scaling)	✓ (Enhanced Context-Aware Scaling)
Precision Format	BF16	FP8 (Fine-Grained Mixed Precision)	FP8 (Per-Group Scaling, FP32 Accumulation)
Adaptive Routing for MLA	✗	✓ (Static Adaptive Routing)	✓ (Load-Balanced Dynamic Routing)
Inference Latency Reduction	✓ (KV Compression Reduces Latency)	✓ (10% Faster than V2)	✓ (10% Faster than V3)
RL Enhancements	✗	✗	✓ (GRPO for Adaptive MLA Optimization)
Numerical Stability Improvements	✓ (Basic Stability Enhancements)	✓ (FP8 with Mixed Precision)	✓ (FP8 with RL-Guided Stability Mechanisms)
Long-Context Performance	✓ (Supports Longer Contexts)	✓ (Further Optimized)	✓ (Enhanced with RL-Guided Token Prioritization)



算法优化——多词元预测 (MTP)

一次预测多个词元

- ◆ 提高推理速度
- ◆ 提高训练数据的利用率
- ◆ 提高模型预测能力






算法优化——多词元预测（MTP）

Feature	DeepSeek-V3	DeepSeek-R1
Sequential MTP Modules	✅ Structured pipeline with sequential depth modules	✅ Enhanced with cross-depth residual connections
Shared Embeddings for MTP	✅ Shared token embeddings across modules	✅ Further optimized with depth-conditioned routing
Prediction Granularity	❌ Fixed number of future token predictions per module	✅ Adaptive token horizon based on sequence complexity
Loss Function Optimization	❌ Uniform loss weighting across MTP depths	✅ Depth-aware weighting for optimized learning
Memory Optimization Strategy	✅ Shared output heads for reduced memory footprint	✅ Further improved with depth-conditioned layer sharing
Inference Speed Boost via MTP	✅ Basic speculative decoding	✅ Probabilistic speculative decoding, reducing rejection rates by 40%
Training Efficiency Improvement	✅ 15% increase in data efficiency	✅ 22% faster convergence with improved loss prioritization
Long-Term Coherence in Predictions	✅ Improved over next-token prediction models	✅ 18% better perplexity in long-form text
Speculative Decoding Acceptance Strategy	❌ Strict token match required for validation	✅ Probabilistic validation based on confidence threshold
Impact on Latency Reduction	✅ Moderate improvement in decoding speed	✅ 1.5× faster inference due to reduced rejection rates



算法优化——多词元预测 (MTP)

Component	DeepSeek-V2 (BF16)	DeepSeek-V3 (FP8)
Query/Key Compression	$d_c=4d_h$	$d_c=3d_h$
KV Cache Storage	BF16	FP8
RoPE Application	Full Precision	Decoupled, FP8
Attention Computation	BF16	FP8 + FP32 Accumulation





Infra优化——DualPipe

如何更好地进行多机并行，减少并行气泡？

更均匀+细粒度的划分 (计算与通讯几乎可以完全并行)

◆ 将每个块划分为4个组件：注意力、all-all调度、MLP、all-all组合

双向流水线调度

◆ 可同时从流水线两端提供微批次，并且大部分通信可以完全重叠



样本1

样本20







Infra优化——跨节点All-All通信

如何更好地进行all-all调度， all-all组合？

- ◆ **方法：**跨节点 GPU 通过 IB 通信，节点内通过 NVLink 通信，**每个词元最多调度到 4 个节点**，从而减少 IB 通信量。同时使用**warp技术**做调度和组合的优化
- ◆ **结果：**每个词元能在不产生 NVLink 额外开销的情况下，在每个节点上平均选择 3.2 个专家。即每个token扩展到最多 13 个专家（4 个节点 × 3.2 个专家），而通信成本不变





DeepSeek模型优化效果

DeepSeek-V3的训练成本约为Llama-3.1（规模甚至更小）的**1/10**

模型名称	参数量 /个	训练设备	训练卡时 / $\times 10^6$ 小时	训练成本 / $\times 10^6$ 美元
Llama	65B	A100-80GB, 2048 块	≈ 1.0	≈ 1.4
Llama-2	70B	A100-80GB, 约 2000 块	≈ 1.7	≈ 2.4
Llama-3	70B	H100-80GB, 数量未知	≈ 6.4	≈ 12.8
Llama-3.1	405B	H100-80GB, 约 16000 块	≈ 30.8	≈ 61.6
Llama-3.3	70B	H100-80GB, 数量未知	≈ 7.0	≈ 14.0
DeepSeek-V3	671B	H800-80GB, 2048 块	≈ 2.8	≈ 5.6

