

第六章 链路层

1. 引论和服务

1.1 导引

网络层解决了一个网络如何到达另一个网络的路由问题。

在一个网络内部如何由一个节点（主机或者路由器）到达另一个相邻节点。链路层的**点到点**传输层功能。

1.2 网络节点的连接方式

- 点到点连接
- 多点连接：共享型介质；通过网络交换机

数据链路层负责从一个节点通过链路将（帧中的）数据报发送到相邻的物理节点（一个子网内部的2节点）。

1.3 链路层：上下文

数据报在不同的链路上以不同的链路协议传送：

- 第一条链路：以太网
- 中间链路：帧中继链路
- 最后一跳：802.11

不同的链路协议提供不同的服务

1.4 链路层服务

1. 成帧，链路接入：

- 将数据报封装在帧中，加上帧头、帧尾部
- 如果采用的是共享性介质，信道接入获得信道访问权
- 在帧头部使用MAC地址来标示源和目的

2. 在一个网络内相邻两个节点完成可靠数据传递

- 在低出错率的链路上（光纤和双绞线电缆）很少使用
- 在无线链路经常使用：出错率高

不是所有的链路层都提供这些服务

3. 流量控制：使得相邻的发送和接收节点的速度匹配


4. 错误检测：差错由信号衰减和噪声引起；接受方检测出的错误：通知发送端进行重传或丢弃帧

5. 差错纠正：接收端检查和纠正bit错误，不通过重传来纠正错误


6. 半双工和全双工：半双工：链路可以双向传输，但是一个只有一个方向

1.5 链路层的实现位置

- 在每一个主机上：也在每个路由器上；交换机的每个端口上
- 链路层功能在“适配器”上实现或者在一个芯片组上
- 接到主机的系统总线上
- 硬件、软件和固件的综合体



1.6 适配器通信



- 发送方：在帧中封装数据报；加上差错控制编码，实现rdt和流量控制
- 接受方：检查有无差错，执行rdt和流量控制功能；解封装数据报，将其交给上层


2. 差错检测和纠正

2.1 错误检测

EDC=差错检测和纠正位（冗余位）

D=数据由差错检测保护，可以包含头部字段

更长的EDC字段可以得到更好的检测和纠正效果，错误检测不是百分百可靠




2.2 奇偶校验

2.3 Internet校验和

目的：检测在传输报文段时的错误（仅用在传输层）

2.4 CRC

- 强大的差错检测码
- 将数据比特 D , 看成是二进制的数
- 生成多项式 G : 双方协商 $r+1$ 位模式 (r 次方)
 - 生成和检查所使用的位模式
- 目标: 选择 r 位 CRC 附加位 R , 使得
 - $\langle D, R \rangle$ 正好被 G 整除 (modulo 2)
 - 接收方知道 G , 将 $\langle D, R \rangle$ 除以 G . 如果非 0 余数: 检查出错误!
 - 能检出所有少于 $r+1$ 位的突发错误
- 实际中广泛使用 (以太网、802.11 WiFi、ATM)



$$D * 2^r \text{ XOR } R$$

mathematical formula

示例：


- 分配片给每个节点专用
- 随机访问：
 - 信道不划分，允许冲突
 - 冲突后恢复
- 依次轮流：
 - 节点依次轮流
 - 但是有很多数据传输的节点可以获得较长的信道使用权

3.3 信道划分

3.3.1 TDMA

TDMA: time division multiple access


- 轮流使用信道，信道的时间分为周期
- 每个站点使用每周期中固定的时隙(长度=帧传输时间)传输帧
- 如果站点无帧传输，时隙空闲-》浪费
- 如：6站LAN，1、3、4有数据报，时隙2、5、6空闲



3.3.2 FDMA

FDMA: frequency division multiple access

- 信道的有效频率范围被分成一个个小的频段
- 每个站点被分配一个固定的频段
- 分配给站点的频段如果没有被使用，则空闲
- 例如：6站LAN，1、3、4有数据报，频段2、5、6空闲



3.3.3 CDMA

○CDMA (code division multiple access) :

- 所有站点在整个频段上同时进行传输, 采用编码原理加以区分
- 完全无冲突
- 假定: 信号同步很好, 线性叠加

○比方

- TDM: 不同的人在不同的时刻讲话
- FDM: 不同的组在不同的小房间里通信
- CDMA: 不同的人使用不同的语言讲话

3.4 随机存取协议

- 当节点有帧要发送时, 以信道带宽的全部发送, 没有节点间的预先协调
- 两个或更多节点同时传输, 会发生冲突
- 随机存取协议规定了如何检测冲突以及如何从冲突中恢复
- 主要有以下几种:
 - Slotted ALOHA
 - ALOHA
 - CSMA, CSMA/CD, CSMA/CA


3.4.1 Slotted ALOHA

假设:

- 所有帧是等长的
- 时间被划分成相等的时隙, 每个时隙可发送一帧
- 节点只在时隙开始时发送帧
- 节点在时钟上是同步的
- 如果两个或多个节点在一个时隙传输, 所有的站点都能检测到冲突

运行:

- 当节点获取新的帧, 在下一个时隙传输
- 传输时没有检测到冲突, 成功; 节点能够在下一个时隙发送新帧
- 检测时如果检测到冲突, 失败; 节点在每一个随后的时隙以概率 p 重传帧直到成功



优点：

- 节点可以以信道带宽全部连续传输
- 高度分布：仅需要节点之间在时隙上的同步
- 简单

缺点：

- 存在冲突，浪费时隙
- 即使有帧要发送，仍然有可能存在空闲的时隙
- 节点检测冲突的时间 < 帧传输的时间
- 需要时钟上同步

效率：


假设N个节点，每个节点都有很多帧要发送，在每个时隙中的传输概率是 p ，一个节点成功传输的概率是 $p(1-p)^{N-1}$ ，任何一个节点的成功概率是 $Np(1-p)^{N-1}$ ，N个节点的最大效率即为求 $f(p) = Np(1-p)^{N-1}$ 的最大值，最大为 $\frac{1}{e} = 37\%$ 。

3.4.2 ALOHA

无时隙ALOHA：简单、无须节点间在时间上同步

当有帧需要传输：马上传输

冲突的概率增加：帧在 t_0 发送，和其他在 $[t_0 - 1, t_0 + 1]$ 区间内开始传输的帧冲突，和当前帧冲突的区间增大了一倍



效率：

$$P(\text{指定节点成功}) = P(\text{节点传输}) \cdot P(\text{其他节点在}[t_0 - 1, t_0] \text{不传}) \cdot P(\text{其他节点在}[t_0, t_0 + 1] \text{不传})$$
$$= p \cdot (1-p)^{N-1} \cdot (1-p)^{N-1} = p(1-p)^{2N-2}$$

最大为 $\frac{1}{2e}$

3.4.3 CSMA (载波侦听多路访问)

引入：如何提高ALOHA的效率，在发之前不管有无其他节点在传输。

CSMA：在传输前先侦听信道：

- 如果侦听到信道空闲，传输整个帧
- 如果侦听到信道忙，推迟传输

类比：不要打断别人正在进行的说话！

CSMA冲突：

- 冲突由**传播延迟**造成：两个节点可能侦听不到正在进行的传输
- 整个冲突帧的传输时间都被浪费了，是无效的传输
- 传播延迟决定了冲突的概率


3.4.4 CSMA/CD (collision detection)

- 和在CSMA中一样发送前侦听信道
- 没有传完一个帧就可以在短时间内检测到冲突
- 冲突发生时则传输终止，减少对信道的浪费

冲突检测CD技术：（有线局域网中容易实现）

- 检测信号强度，比较传输与接收到的信号是否相同
- 通过周期的过零点检测

类比：礼貌的对话人！



对信道的浪费减少了

以太网CSMA/CD算法：

1. 适配器获取数据报，创建帧
2. 发送前：侦听信道CS (carrier sense)
闲：开始传送帧；忙：一直等到闲再发送
3. 发送过程中，冲突检测CD (collision detection)
没有冲突：成功；检测到冲突：放弃，之后尝试重传
4. 发送方适配器检测到冲突，除放弃外，还发送一个Jam信号，所有听到冲突的适配器也是如此。作用：强化冲突，让所有站点都知道冲突的发生，广而告之。
5. 如果放弃，适配器进入指数退避状态：
在第 m 次失败后，适配器随机选择一个 $\{0, 1, 2, \dots, 2^{m-1}\}$ 中的 K ，等待 $K * 512$ 位时，然后转到步骤2。这称为二进制指数退避算法。

指数退避算法：适配器试图适应当前负载，在一个变化的碰撞窗口中随机选择时间点尝试重发

- 高负载：重传窗口时间大，减少冲突，但等待时间长
- 低负载：使得各站点等待时间少，但冲突概率大

CSMA/CD效率:

- t_{prop} = LAN上2个节点的最大传播延迟
- t_{trans} = 传输最大帧的时间
- $efficiency = \frac{1}{1+5t_{prop}/t_{trans}}$
- 当 t_{prop} 变为0或者 t_{trans} 变为无穷大时, 效率变为1
- 比ALOHA更好的性能, 而且简单, 廉价, 分布式

3.4.5 CSMA/CA (collision avoidance)

适用于无线局域网中

- 802.11:CSMA——发送前侦听信道: 不会和其他节点正在进行的传输发生冲突
- 802.11: 没有冲突检测!


无法检测冲突: 自身信号远远大于其他节点信号

即使能CD: 冲突不代表成功

目标: CA, 事前进行冲突避免

具体步骤:

- 发送方:
 1. 如果站点侦测到信道空闲持续DIFS长, 则传输整个帧
 2. 如果侦测到信道忙碌, 那么选择一个随机回退值, 并在信道空闲时递减该值; 如果信道忙碌, 回退值不变。到数到0时发送整个帧; 如果没有收到ACK, 增加回退值, 重复2
- 802.11接收方: 如果帧正确, 则在SIFS后发送ACK



在递减时, 侦听到了信道空闲为什么不发送, 而要等到0时再发送?

[CSMA/CA详细分析](#)

无法完全避免冲突: (隐藏站点的存在)

无法完全避免冲突

两个站点相互隐藏:

- A,B 相互隐藏, C在传输
- A,B选择了随机回退值
- 一个节点如A胜利了, 发送
- 而B节点收不到, 顺利count down到0 发送
- A,B的发送在C附近形成了干扰



选择了非常靠近的随机回退值:

- A,B选择的值非常近
- A到0后发送
- 但是这个信号还没到达B时
- B也到0了, 发送
- 冲突


冲突避免:

思想: 允许发送方“预约”信道, 而不是随机访问该信道, 避免长数据帧的冲突。


- 发送方首先使用CSMA向BS发送一个小的RTS分组 (RTS可能会冲突, 但是由于比较短, 浪费信道较少)
- BS广播CTS, 作为RTS的响应
- CTS能够被所有涉及到的节点听到
 - 发送方发送数据帧
 - 其他节点抑制发送

采用小的预约分组, 可以完全避免数据帧的冲突

冲突避免: RTS-CTS 交换



3.4.6 线缆接入网络




- 下行(广播)信道:通过FDM分成若干信道,互联网,数字电视等.互联网信道:只有一个CMTS在其上传输
- 上行信道:
多路访问:所有用户使用;接着TDM分成微时隙
部分时隙:分配;竞争

DOCSIS: data over cable service interface specification

- 采用FDM进行信道的划分:若干上行,下行信道
- 下行信道:在下行MAP帧中:CMTS告诉各节点微时隙分配方案,分配给各站点的上行微时隙;另外头端传输下行数据给各个用户
- TDM上行信道:
采用TDM的方式将上行信道分成若干微时隙:MAP指定;
站点采用分配给它的微时隙上行数据传输:分配;
在特殊的上行微时隙中,各站点请求上行微时隙:竞争
 - 各站点对于该时隙的使用是随机访问的
 - 一旦碰撞(请求不成功,结果是在下行的MAP中没有为它分配,则二进制退避)选择时隙上传输

b.5 线缆接入网络



3.5 轮流MAC协议(Taking turns)


3.5.1 轮询

- 主节点邀请从节点依次传送
- 缺点:

轮询开销:轮询本身消耗信道带宽

等待时间:每个节点需等到主节点轮询后开始传输,即使只有一个节点,也需要等到轮询一周后才能够发送

单点故障:主节点失效时造成整个系统无法工作




3.5.2 令牌传递

- 控制令牌(token)循环从一个节点到下一个节点传递
- 令牌报文:特殊的帧
- 缺点:

令牌开销:本身消耗带宽

延迟:只有等到抓住令牌,才可传输

单点故障:令牌丢失系统级故障,整个系统无法传输;生成令牌机制复杂



3.6 总结

多点接入问题：对于一个共享型介质，各个节点如何协调对它的访问和使用？

- 信道划分：按时间、频率或者编码:TDMA、FDMA、CDMA
- 随机访问 (动态)
 - ALOHA, S-ALOHA, CSMA, CSMA/CD
 - 载波侦听: 在有些介质上很容易 (wire: 有线介质), 但在有些介质上比较困难 (wireless: 无线)
 - CSMA/CD : 802.3 Ethernet网中使用
 - CSMA/CA : 802.11WLAN中使用
- 依次轮流协议
 - 集中: 由一个中心节点轮询; 分布: 通过令牌控制
 - 蓝牙、FDDI、令牌环

4.LANs

4.1 MAC地址和ARP

4.1.1 IP地址和MAC地址

IP地址32位，属于网络层地址。前n-1跳用于使数据报到达目的IP子网，最后一跳到达子网中的目标节点。

MAC地址：用于使帧从一个网卡传递到与其物理连接的另一个网卡（在同一个物理网络中）。48位MAC地址固化在适配器的ROM，有时也可以通过软件设定。理论上全球任何2个网卡的MAC地址都不相同。

为什么需要IP地址和MAC地址两种地址？


- IP地址是分层的：一个子网所有站点网络号一致，路由聚集，减少路由表；IP地址完成网络到网络的交付
- MAC地址是一个平面的：每一个网卡的MAC地址是唯一的；可以完成一个物理网络内部的节点到节点的数据交付

IP地址和MAC地址分离优点：

- 网卡坏了，IP不变，可以捆绑到另外一个网卡上
- 物理网络还可以除IP之外支持其他网络层协议

4.1.2 LAN地址和ARP

局域网每个适配器都有唯一的LAN地址：



MAC地址由IEEE管理和分配;

制造商购入MAC地址空间;

MAC平面地址: 支持移动: 可以将网卡接到其他网络;

IP地址有层次: 不能移动。


4.1.3 ARP: Address Resolution Protocol

在LAN上的每个IP节点都有一个ARP表

ARP表: 包括一些LAN解当IP/MAC地址的映射

<IP address;MAC address;TTL>TTL是地址映射失效的时间

问题:已知B的IP地址, 如何确定B的MAC地址?



ARP是即插即用的: 节点自己创建ARP的表项, 无需网络管理员的干预

ARP协议：在同一个LAN(网络)

- A要发送帧给B(B的IP地址已知), 但B的MAC地址不在A的ARP表中
 - A广播包含B的IP地址的ARP查询包
 - Dest MAC address = FF-FF-FF-FF-FF-FF
 - LAN上的所有节点都会收到该查询包
 - B接收到ARP包, 回复A自己的MAC地址
 - 帧发送给A
 - 用A的MAC地址(单播)
- A在自己的ARP表中, 缓存IP-to-MAC地址映射关系, 直到信息超时
 - 软状态: 靠定期刷新维持的系统状态
 - 定期刷新周期之间维护的状态信息可能和原有系统不一致
- ARP是即插即用的
 - 节点自己创建ARP的表项
 - 无需网络管理员的干预


4.2 Ethernet

4.2.1 简介

- 目前最主流的LAN技术: 98%占有率
- 廉价
- 最早广泛应用的LAN技术
- 比令牌网和ATM网络简单、廉价
- 带宽不断提升

4.2.2 物理拓扑

- 总线: 所有节点在一个碰撞域内, 一次只允许一个节点发送; 可靠性差
- 星型(目前最主流):
 - 连接选择: Hub或者switch
 - 现在一般是交换机在中心
 - 每个节点以及相连的交换机端口使用独立的以太网协议



4.2.3 以太帧结构

发送方适配器在以太网帧中封装IP数据报，或其他网络层协议数据单元



前导码(preamble): 用来同步接收方和发送方的时钟速率

地址: 6字节源MAC地址, 目标MAC地址

类型: 指出高层协议

CRC: 在接收方校验

4.2.4 以太网服务

- 无连接: 帧传输前, 发送方和接收方之间没有握手
- 不可靠: 接收方适配器不发送ACKs或者NAKs给发送方

4.3 WLAN

IEEE 802.11 WLAN:

所有的802.11标准都是用CSMA/CA进行多路访问

所有的802.11标准都有基站模式和自组织网络模式

体系结构:


- 无线主机与基站通信: 基站 (base station)=接入点(access point)
- 基础设施模式下的基本服务集(BSS)包括以下构件:
 - 无线主机
 - 接入点: 基站
 - 自组织模式下: 只有无线主机

关于WLAN详细的介绍请自行查看

4.4 Switch

4.4.1 Hub: 集线器

- 网段: 可以允许一个站点发送的网络范围
 - 在一个碰撞域, 同时只允许一个站点在发送
 - 如果有2个节点同时发送, 则会碰撞
 - 通常拥有相同的前缀, 比IP子网更详细的前缀
- 所有以Hub连在一起的站点处在一个网段, 处在一个碰撞域
 - 骨干hub将所有网段连在一起
- 通过hub可扩展节点之间的最大距离




4.4.2 Switch:交换机

- 链路层设备：
 - 对帧进行存储和转发
 - 对于到来的帧，检查帧头，根据目标MAC地址进行选择转发
 - 当帧需要向某个网段进行转发，需要使用CSMA/CD进行接入控制
 - 通常一个交换机端口对应一个独立网段
- 透明：主机对交换机的存在可以不关心
- 即插即用，自学习：无需配置

多路同时传输：

- 主机有一个专用和直接到交换机的连接
- 交换机缓存来的帧
- 对每个帧进入的链路使用以太网协议，没有碰撞；全双工
 - 每条链路都是一个独立的碰撞域
 - MAC协议在其中的作用弱化了
- 交换：A-to-A'和B-to-B'可以同时传输，没有碰撞




交换机转发表（自学习）：

- 交换机通过学习得到哪些主机可以通过哪些端口到达

自学习，转发的例子

- 帧的目标: **A'**, 不知道其位置在哪: **泛洪**
- ❖ 知道目标A对应的链路: **选择性**发送到那个端口



MAC addr	interface	TTL
A	1	60
A'	4	60


switch table
(initially empty)

6: 数据链路层和局域网 102

泛洪和选择性转发

交换机可以被级联在一起:

- ❖ 交换机可被**级联**到一起



Q: A to G的发送 - 交换机S₁ 如何知道经过从S₄ 和S₃最终达到F?

- ❖ **A:** 自学习! (和在一个交换机联接所有站点一样!)

4.4.3 交换机vs路由器

- 都是存储转发设备, 但层次不同
 - 交换机: 链路层设备: 检查链路层头部
 - 路由器: 网络层设备: 检查网络层头部
 - 都有转发表:
 - 交换机: 维护交换表, 按照MAC地址转发
- 执行过滤、自学习和生成树算法
- 即插即用: 二层设备, 速率高

ARP表项随着站点数量增多而增多

- 路由器：维护路由表，执行路由算法


路由算法能够避免环路，无需执行生成树算法

不是即插即用，配置网络地址（子网前缀）

三层设备，速率低

4.5 VLANs

基于端口的VLAN：交换机端口成组，以至于单个的交换机可以分成若干虚拟LANs。




- 流量隔离：从/到1-8端口的流量只会涉及到1-8
- 动态成员：成员可以在VLANs之间动态分配
- 在VLANs间转发：通过路由器进行转发（就像他们通过各自的交换机相联一样）

VLANs互联多个交换机：

- 方法：各交换机每个VLAN一个端口和另外一个交换机相应的VLAN端口相连——扩展性问题
trunk port 干线端口：多个交换机共享定义的VLAN，在它们之间传输帧

802.1Q VLAN 帧结构：



5.链路虚拟化：MPLS

MPLS (Multiprotocol label switching) :从IP网络来看，将一组支持MPLS的网络虚拟成链路的技术。

MPLS网络按照标签label进行分组的转发：

- 类似于virtual circuit
- 有基于标签的转发表

- 基于虚电路表

纯IP网络是按照IP地址对分组进行转发的：

前缀匹配，转发的方法固定

无法控制IP分组的路径，无法支持流量工程


也无法对一个IP分组流进行资源分配，性能无法保证

标签交换的过程：

- 入口路由器：LER对进入的分组按照EFC的定义打上标签
- 在MPLS网络中（虚拟成了链路）对分组按照标签进行交换
- 到了出口路由器，再将标签摘除
- 支持了MPLS的路由器组成的网络，从IP网络的角度来看虚拟成了链路

关键思想：使用固定长度的标签进行高速率IP转发（而不是使用IP地址采用最长前缀匹配）

- 但是IP数据报仍然保留IP地址！
- 在帧和其封装的分组之间加入一个**垫层**，标签交换使能的路由器使用垫层信息进行分组转发，不解析分组目标地址




具有MPLS能力的路由器称为标签交换路由器，基于标签的值进行分组的转发（而非检查IP地址，MPLS转发表和IP转发表相互独立）。

MPLS vs IP路径：


- IP路由：到达目标的路径仅仅取决于目标地址
- MPLS路由：到达目标的路由，可以基于源和目标地址

快速重新路由：在链路失效时，采用预先计算好的路径




MPLS信令：

- 修改OSPF，IS-IS链路状态泛洪协议来携带MPLS路由信息
- MPLS使能的路由器采用RSVP-TE信令协议在下游路由器上来奖励MPLS转发表



MPLS转发表:




6.数据中心网络

数万-数十万台主机构成DC网络，密集耦合、距离临近：

- 电子商务
- 内容服务器
- 搜索引擎

挑战：

- 多种应用，每一种都服务海量的客户端
- 管理/负载均衡，避免处理、网络和数据的瓶颈





Datacenter networks: protocol innovations

- link layer:
 - RoCE: remote DMA (RDMA) over Converged Ethernet
- transport layer:
 - ECN (explicit congestion notification) used in transport-layer congestion control (DCTCP, DCQCN)
 - experimentation with hop-by-hop (backpressure) congestion control
- routing, management:
 - SDN widely used within/among organizations' datacenters
 - place related services, data as close as possible (e.g., in same rack or nearby rack) to minimize tier-2, tier-1 communication

Google Networking: Infrastructure and Selected Challenges (Slides:
<https://networkingchannel.eu/google-networking-infrastructure-and-selected-challenges/>



7.A day in the life of web request
